최신 논문을 근거로 하는 모델에 사용할 알고리즘 선정 과정임
4가지 대안을 뽑아봄
구조는 최근 개발된 알고리즘+필수적으로 필요한 고전 알고리즘

우선순위 1순위부터 4순위까지 뽑고
왜 선정했는지 이유 분석 적혀있음

순위 상관 없이 필요하면 가져다 쓸 예정

네 안건을 한 번에 비교하기

어선 사고예방을 위한 항적데이터 분석 · Python / 일반 노트북 CPU 기준

1순위 · TabM 조합
ICLR 2025 · 분류 주력 후보
TabM + 작은 LightGBM
숫자 특징으로 먼저 비교

2순위 · RealMLP 조합
NeurIPS 2024 · 분류 대안
RealMLP + 작은 LightGBM
1순위와 같은 조건에서 비교

3순위 · DTE 조합
ICLR 2024 · 이상탐지 확장
선택한 분류기 + DTE + 전역 기준
분류와 다른 역할을 담당

4순위 · GIST 참고 조합
AAAI 2025 · 조건부 이미지 실험
작은 이미지 CNN + 기하 분류기
원 논문과 다른 입력을 명시

이 순서는 무엇을 뜻하나?

[판단] 입력을 만들 수 있는 정도, 검증의 용이성, CPU 비용을 기준으로 정한 실행 순서입니다. NeurIPS의 대표 후보는 앞서 제시한 RealMLP로 한정했습니다.

쉽게 말하면: 1·2순위는 조업형태를 고르는 대안입니다. 3순위는 이상징후 점수를 더하고, 4순위는 이미지가 도움이 되는지 확인하는 실험입니다. 네 방법을 모두 넣을 필요는 없습니다.

현재 확정할 수 없는 것
샘플 10행으로 추천 순위의 성능을 입증하거나 최적 혼합 비중을 정할 수 없습니다. 논문이 우리 어선·라벨·사고 조기 탐지 조건을 직접 검증했다고 주장하지 않습니다.

읽는 순서: 입력 2쪽 → 네 안건 3-6쪽 → 결합·과적합·평가 7-9쪽 → CPU·실험 선택 10-11쪽 → 출처 12쪽 → 기존 가이드 변경 13쪽.

아직은 샘플데이터니까 맛보기로 볼 것

공통 입력: 글자를 공간 정보로

[직접 확인] 샘플 전체 10행·10척. 모두 2025-01-01의 시간대 0이며 연속 이력·점별 시각·사고정보가 없습니다.

샘플에서 실제로 확인한 수치
자망 4 / 연안복합 4 / 통발 1 / 채낚기연승낚시 1행. 16개 구성 선·246점 중 연속 동일 좌표 쌍이 158개입니다. 의미 있는 열 5개와 전부 비어 있는 열 7개를 확인했습니다.

원본 float64 좌표 (확대)



동일 축척 · 표시 폭 약 2.0m

절대 좌표를 먼저 float32로 변환

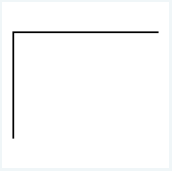


동일 축척 · 표시 폭 약 2.0m

96×96 / 고정 폭 100m

정사각 범위 100.00m · 약 1.053m/픽셀

96×96 / 형상 폭 정규화



정사각 범위 1.43m · 약 0.015m/픽셀

실제 6번 샘플: 선 내부 길이 약 2.2m(구면 거리 근사). 위 두 그림은 같은 축척입니다. 아래는 같은 좌표를 다른 이미지 축척으로 그린 결과입니다.

필수 순서: WKT 파싱 → float64 → 지역 상대 좌표

WKT는 좌표 목록을 글자로 저장한 형식입니다. Shapely 등으로 파싱하고, 경도(X)·위도(Y)와 선 경계를 보존합니다. 좌표계 확인 후 거리 계산을 정합니다. [S2]

쉽게 말하면: float64는 소수를 세밀하게 저장하고, float32는 저장 크기를 줄인 숫자 형식입니다. 절대 경도를 먼저 float32로 줄이면 128°·위도 35° 근처에서 동서 약 1.39m 간격으로 반올림될 수 있어 기준점을 뺀 뒤 줄입니다. 여러 선 사이를 잇지 않으며, 이 간격은 GPS 오차가 아닙니다.

문자열 직접 학습은 우선순위가 낮습니다. 같은 좌표의 문자 표기가 달라지고 공간 관계를 따로 배워야 합니다. 이미지도 원래 없던 시각을 만들지 못합니다. 속도·가속도·체류시간은 점별 시각 없이 생성하지 않습니다.

<추가로 생각해볼 점(개인 아이디어) - 데이터 전처리 과정>
좌표를 픽셀 값으로 변환해서 점으로 표기하는 방법이 원초적이라고 생각함

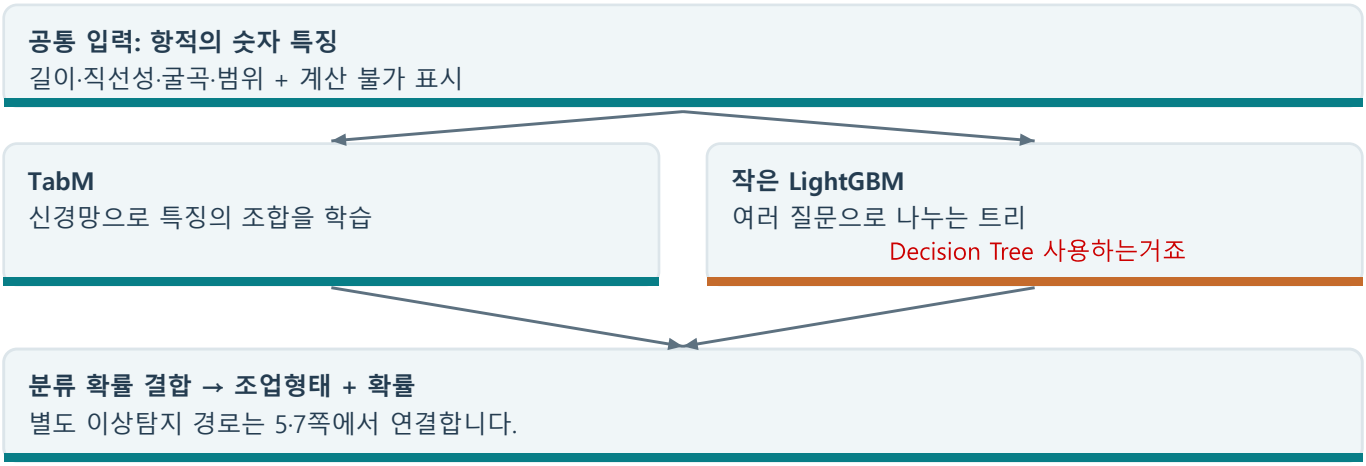
1) binary 0이랑 1로 구성하고 항적 지나가면 1, 아니면 0으로 만들기

2) 1은 빨간색 점으로, 0은 빈 공간으로 설정해서 점이 찍혀있는 부분을 연결하여 이를 이미지화

3) 만든 이미지를 바탕으로 학습시키는 방법

1순위: TabM + 작은 LightGBM

[연구 사실] TabM · ICLR 2025. 표형 데이터에서 가중치를 공유하는 여러 신경망 예측을 학습합니다. [R1]



추천하는 이유와 논문 근거

논문은 다양한 표형 데이터에서 효율적인 내부 앙상블을 평가했습니다. 항적의 길이·직선성·굴곡을 숫자 표로 만들면 적용 가능한 입력 형태입니다. 이 연결은 **[적용 추론]**입니다.

쉽게 말하면: 앙상블은 여러 예측을 모으는 방법입니다. TabM은 예측 멤버들이 대부분의 계산 규칙을 함께 사용합니다. 같은 알고리즘 계열이므로 서로 다른 알고리즘을 섞으려면 LightGBM을 별도로 비교·결합합니다.

사용하기 위한 필수 조건

고정된 열의 숫자 특징·조업 라벨·선박 그룹 분할이 필요합니다. 결측 대체와 수치 변환은 학습 선박에서만 정합니다. 공식 구현의 수치 입력·학습 절차를 기준으로 시작합니다.

쉽게 말하면: 행마다 점 수가 달라도 "길이, 굴곡, 범위…"처럼 같은 순서의 숫자 목록을 만들어 넣습니다. 계산 불가 값은 학습 부분에서 채우고 별도 표시를 남깁니다.

CPU 비용과 채택 조건

[제안] 공유 모델의 폭·깊이·내부 멤버 수를 줄여 비교합니다. TabM 단독, LightGBM 단독, 두 모델 결합을 같은 검증에서 시험합니다. 베이스라인 비교 실험이 필요하다는 거죠

쉽게 말하면: 공유 가중치가 있다고 일반 신경망·트리보다 항상 빠르지는 않습니다. 결합이 신규 선박 F1을 안정적으로 높이거나 같은 성능에서 비용을 줄일 때 채택합니다. 과적합 감소는 보장이 아닙니다.

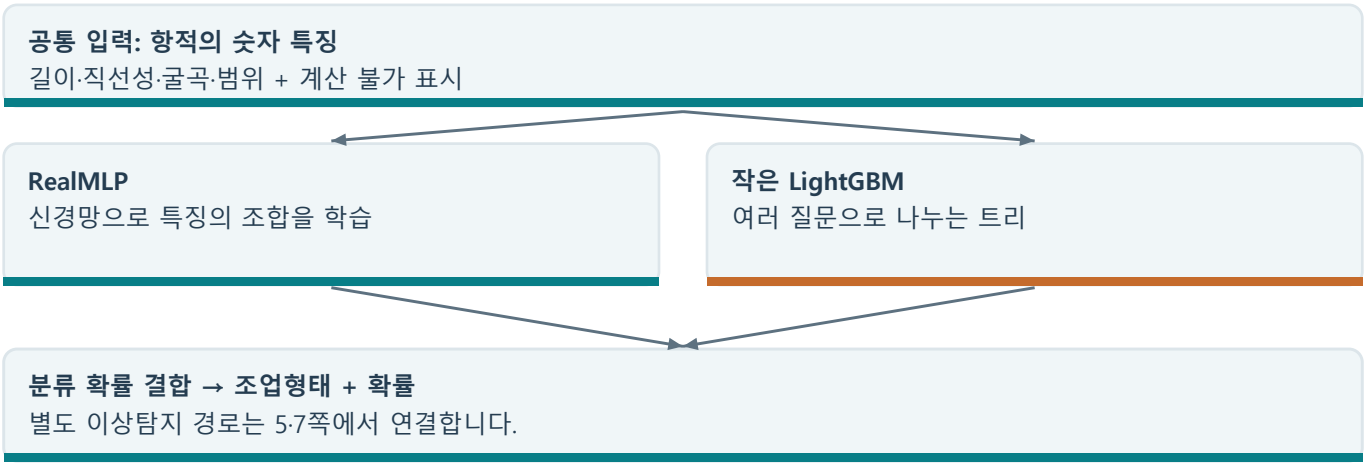
여기서 모델의 크기가 커지는 것도 우려해야할듯

제출 경로

과제 1은 조업형태와 그 확률을 냅니다. 과제 2는 별도 전역 이상 기준에서 시작합니다. 현재 분류의 확신이 낮다는 이유만으로 이상점수를 낮추지 않습니다.

2순위: RealMLP + 작은 LightGBM

[연구 사실] NeurIPS 2024. 기존 MLP의 전처리·초기화·학습 설정을 표형 데이터에 맞게 개선한 연구입니다. [R2]



이 안건의 가치와 검증 범위

논문은 118개 데이터에서 기본 설정을 정하고, 분리된 90개 데이터에서 평가했습니다. 원 연구의 여러 모델 결합과 여기의 두 모델 조합은 동일한 실험이 아닙니다. [R2]

쉽게 말하면: MLP는 숫자를 여러 층에서 조합해 배우는 신경망입니다. RealMLP는 처음부터 많은 설정을 뒤지는 부담을 줄이는 후보입니다. 논문의 성능을 우리 두 모델 조합의 성능으로 옮겨 쓸 수는 없습니다.

사용하기 위한 필수 조건

숫자 표와 라벨이 필요합니다. 확인한 pytabkit 구현은 숫자 NaN을 사전 대체해야 하며, 자체 수치 전처리가 있어 외부 표준화를 무조건 중복하지 않습니다. CPU와 외부 검증 입력을 지원합니다. [R2 구현]

쉽게 말하면: 빠진 숫자는 학습 부분의 중앙값 등으로 채웁니다. 패키지가 자동으로 행을 나누게 두지 말고, 다른 선박으로 만든 검증 입력을 직접 연결합니다.

1순위와 비교할 때 고정할 것

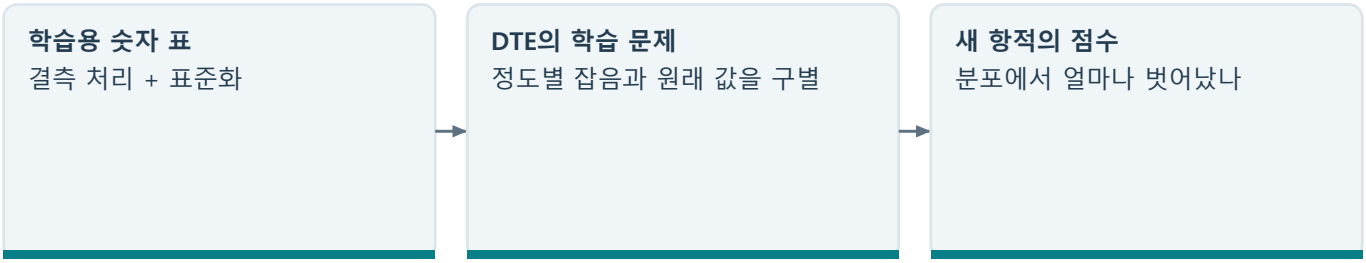
[제안] 같은 특징·선박 분할·학습 시간 예산에서 비교합니다. 공식 기본 설정을 시작점으로 두고 폭·깊이 등 적은 항목만 조정합니다. 자동 반복 학습의 횟수와 비용도 기록합니다.

쉽게 말하면: TabM과 RealMLP를 동시에 크게 튜닝하면 좋은 설정을 우연히 고를 위험이 커집니다. 이름의 최신성보다 분리한 최종 평가와 CPU 측정 결과로 선택을 바꿉니다.

> **2순위의 의미**
> RealMLP가 열등하다고 판정한 것은 아닙니다. TabM과 함께 비교하되, 성능이 비슷하고 더 빠르거나 분할별 변동이 작으면 RealMLP 조합을 최종 주력으로 선택합니다.

3순위: DTE + 전역 이상 기준

[연구 사실] DTE · ICLR 2024. 확산 과정의 잡음 단계를 추정하는 방식으로 이상점수를 만드는 연구입니다. [R3]



DTE 점수 + 전역 이상 기준 → 검증 후 0-1 점수
잡음의 단계는 실제 운항 시간·사고 발생 시간이 아닙니다.

분류 모델을 고른 뒤 추가하는 이유

[제안] ① 또는 ②의 분류기를 고정하고, DTE-Categorical 등 공식 구현 후보를 전역 기준과 비교합니다. 표형 이상탐지의 연구 결과는 근거이나, 사고 조기 탐지에 대한 직접 증거는 아닙니다.

쉽게 말하면: Categorical은 잡음 단계를 여러 범주로 나누어 배우는 구현입니다. 평소 숫자 조합과 다른 항적을 찾되, 학습용 잡음이 가짜 사고는 아닙니다. DTE의 "시간"도 실제 운항 시각이 아닙니다.

사용하기 위한 필수 조건

결측 처리 뒤, 학습 부분에서 평균·표준편차를 정해 표준화합니다. 공식 구현은 이 스케일링을 특히 요구합니다. 정상 후보의 충분한 범위와 이상 혼입 여부를 확인합니다. [R3 구현]

쉽게 말하면: 길이의 큰 숫자가 굴곡의 작은 숫자를 압도하지 않게 맞춥니다. 긴 연속 시계열이 필수인 방법은 아니지만, 10행만으로 정상 분포를 배울 수 있다고 보지는 않습니다.

점수 결합과 오탐 방지

[제안] 먼저 "높을수록 이상"으로 방향을 맞춥니다. DTE와 전역 기준의 원점수를 분리된 설정 자료에서 각각 0-1 순위 점수로 바꾼 뒤 결합을 검토합니다. 두 단독 점수도 남깁니다.

쉽게 말하면: 단위가 다른 두 점수를 바로 더하지 않습니다. 0.9는 기준 자료보다 드문 패턴이라는 뜻이지 사고 확률 90%가 아닙니다. 혼합이 이상을 가릴 수도 있으므로 사건별로 확인합니다.

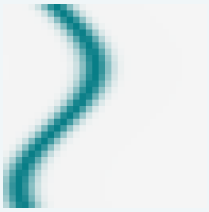
핵심 제약
사고 주변 기록은 정상 후보를 만들 때 별도 관리합니다. 사고가 알려지지 않은 기록도 완전한 정상은 아닙니다. DDPM보다 빠르다는 연구 결과를 Isolation Forest나 노트북보다 빠르다는 주장으로 확대하지 않습니다.

4순위: GIST를 참고한 이미지 조합

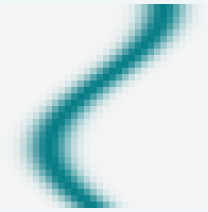
[연구 사실] AAAI 2025의 선박 분류 연구. 현재 자료에서는 원 논문의 재현보다 입력을 바꾼 보조 실험이 적절합니다. [R4]

원 논문 GIST [R4]
속도 / 방향 변화의 값별 빈도
두 채널의 128×128 분포 이미지

속도 분포



방향 변화 분포



가상 분포 개념도 · 실제 논문 데이터 아님

현재 WKT의 수정안 [제안]
실제 좌표를 그린 형상 이미지
기하 특징 분류기와 결합



실제 샘플 2 · 형상 정규화 · 시간 정보 없음

직접 관련 연구지만 입력·라벨이 다릅니다

원 논문은 128분 초과 AIS 구간의 속도(SOG)·진행 방향 변화(ΔCOG) 분포를 이미지로 만듭니다. 트롤·선망·표류식 연승(drifting longliner)을 다루고, 통발·고정식 자망 등 고정 어구는 제외합니다. [R4]

쉽게 말하면: AIS는 선박 위치 등을 보내는 관측 자료입니다. 원 논문의 긴 구간·속도와 우리 한 시간 WKT는 다릅니다. 표류식 연승은 줄을 따라 여러 낚싯바늘을 쓰는 조업이며, 현재 fishing_code 라벨과 직접 대응한다고 볼 수 없습니다.

현재 가능한 조합의 필수 조건

[제안] 선 경계를 지킨 96×96 정도의 형상 이미지와 실제 길이·폭·높이 특징을 함께 사용합니다. 작은 CNN의 분류 확률과 ①/②의 기하 분류 확률을 비교·결합합니다.

쉽게 말하면: CNN은 작은 그림 조각의 모양을 읽는 신경망입니다. 이미지는 같은 좌표를 다시 표현한 것이므로 새 관측이 추가된 것은 아닙니다. 지도 배경·ID·라벨 색은 넣지 않습니다.

이 안건을 보류할 기준

논문 실험은 GPU 환경이며 신규 선박 분할의 동일 조건을 확인하지 못했습니다. 우리 실험에서는 선박을 분리합니다. 긴 구간 필터로 제출해야 할 시간별 행을 없애지 않습니다.

쉽게 말하면: 원 논문의 높은 성적을 우리 성적으로 인용하지 않습니다. 이미지가 기하 특징보다 개선되지 않거나 CPU 비용이 커지면 제외합니다. 점별 시각을 나중에 받아도 미래 구간을 쓰지 않습니다.

명칭: 현재 수정안을 "GIST 재현"으로 쓰지 않습니다. "GIST의 표현 아이디어를 참고한 형상 이미지 모델"로 구분합니다. 원 논문 입력을 실제로 확보하면 별도 재현 실험을 할 수 있습니다.

네 안건을 어떻게 조합할까?

[설계 제안] 분류의 선택과 이상탐지의 선택을 분리합니다. 네 모델을 한꺼번에 평균하지 않습니다.



분류 확률 결합: 적은 비중 후보만 비교

같은 클래스 순서로 맞춘 뒤 p = α·p신경망 + (1-α)·p트리를 사용합니다. α는 예를 들어 0, 0.5, 1부터 설정 자료에서 비교합니다. 0과 1은 각각 단독 모델입니다.

쉽게 말하면: 자망 확률이 신경망 0.8, 트리 0.6이면 반반 결합은 0.7입니다. 과한 확신을 줄여 확률과 실제 정답 비율을 맞추는 것이 확률 보정입니다. 보정·비중 선택은 최종 평가 자료에서 하지 않습니다.

이상점수 결합은 별도의 문제

DTE와 전역 기준을 같은 기준으로 바꾼 점수 qDTE, q전역에 대해 s = β·qDTE + (1-β)·q전역을 비교합니다. 조업별 기준·선박별 과거 기준은 조건이 갖춰지면 추가합니다.

쉽게 말하면: 분류의 α와 이상탐지의 β는 다른 손잡이입니다. 현재 분류 라벨로 기준을 즉시 바꾸면 이상 기동을 다른 조업으로 착각해 숨길 수 있어 전역 경로를 유지합니다.

> **기존 알고리즘도 반드시 남길 비교안**
> LightGBM은 숫자 특징 분류의 비용 비교안입니다. MAD는 평소 중앙값에서 벗어나는 정도를 재는 척도입니다. Isolation Forest는 숫자 공간을 나눌 때 유독 빨리 분리되는 행을 이상 후보로 삼습니다. 이 전역 기준들이 더 좋으면 그것을 채택합니다. [S1,S3]

선박별 기준에는 충분한 과거가 필요합니다. 신규 선박은 전역 기준으로 시작합니다. Test 이력의 사용·갱신은 대회 규칙을 확인하고, 허용되어도 현재 이후 관측·숨겨진 라벨을 쓰지 않습니다.

과적합을 막는 검증 구조

[필수 검증] Test A가 원칙적으로 신규 선박이므로, 같은 선박의 다른 시간이 양쪽에 섞이지 않게 합니다.

학습 선박
A · B · C
특징과 정답으로 학습

설정 선박
D · E
모델 크기·혼합 비중 선택

최종 평가 선박
F · G
선택을 끝낸 뒤 성능 확인

행 수보다 서로 다른 선박 수가 중요합니다

학습·설정·최종 평가의 선박을 분리하고 클래스별 선박 수를 확인합니다. StratifiedGroupKFold는 그룹을 지키며 라벨 비율을 맞추려는 방법이지만 작은 그룹 수에서는 완전한 균형이 불가능합니다. [S1]

쉽게 말하면: 같은 배의 1,000시간을 보고 그 배의 다른 시간을 맞히는 것과 새로운 배를 맞히는 것은 다릅니다. 샘플의 통발·채낚기연승낚시 각 한 척으로는 해당 클래스의 독립 평가를 만들 수 없습니다.

전처리와 증강도 분할 뒤에 합니다

결측 대체·스케일·특징 선택·정상 기준은 학습 부분에서 정합니다. 증강 이미지와 변형 항적은 원래 선박의 분할에만 둡니다. 자기지도 사전학습도 분할 원칙과 허용 데이터 범위를 따릅니다.

쉽게 말하면: 원본이 학습에, 그 복사본이 평가에 있으면 시험 답을 미리 본 셈입니다. 복사와 회전으로 새 선박 수가 늘어나지 않습니다. 회전이 라벨을 보존하는지는 먼저 검증합니다.

정답과 수집 규칙을 외우지 않게 합니다

ID는 그룹·연결 키로 쓰고 분류 입력에서 제외합니다. 절대 위치·관측 품질을 포함한 안과 뺀 안을 비교합니다. 연안 위치가 도움이 될 수 있어도 해역·수집 장치를 외우는지 점검합니다.

쉽게 말하면: 형상만으로 성능이 유지되는지 확인하면 특정 지역의 배를 외운 결과인지 구별하는 데 도움이 됩니다. 분류가 어렵다는 이유로 ID를 다시 넣지 않습니다.

작은 탐색 + 끝에 한 번 확인
각 모델에 적은 크기 후보와 동일 시간 예산을 줍니다. 설정 선박에서 조기 종료·혼합 비중을 고른 뒤 최종 평가 선박은 선택에 사용하지 않습니다. 분할별 성능과 클래스별 결과도 보고합니다.

평가: F1과 조기 경보를 나누기

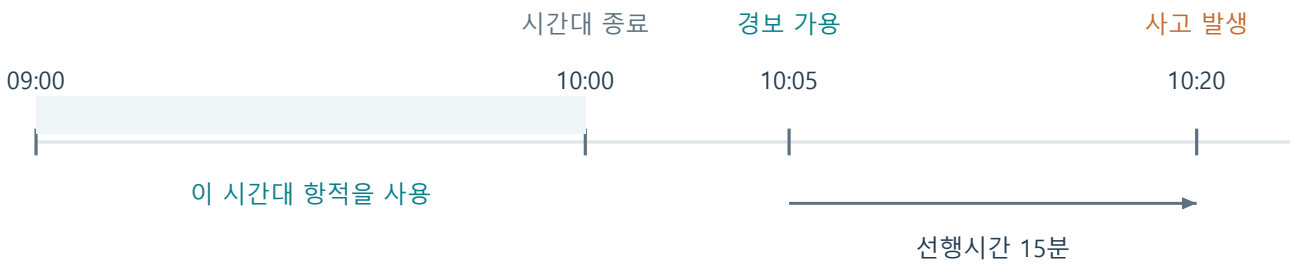
[설명용 가상 예시] 아래 숫자는 실제 학습 결과가 아닙니다. 이상/정상 이진 판정을 예로 듭니다.

	예측: 이상	예측: 정상
실제: 이상	**TP = 15** 이상징후를 탐지	**FN = 5** 이상징후를 놓침
실제: 정상	**FP = 30** 정상을 이상으로 경보	**TN = 950** 정상을 정상으로 판단

TP·FP·FN·TN과 F1

TP는 이상을 맞힌 것, FP는 정상에 낸 경보, FN은 놓친 이상, TN은 정상 판단입니다. 정밀도 = TP/(TP+FP), 재현율 = TP/(TP+FN), F1 = 2TP/(2TP+FP+FN). [S1]

쉽게 말하면: 위 예시는 정밀도 33.3%, 재현율 75%, F1 46.2%인데 정확도는 96.5%입니다. 정상이 많으면 정확도만 높아질 수 있습니다. 조업 다중분류는 클래스별 F1과 그 단순 평균인 Macro-F1도 확인합니다.



가정 예시: 09-10시 항적이 10:05에 사용 가능하고 사고가 10:20이면 선행시간은 15분입니다. 시간대 시작인 09:00을 경보 시각으로 쓰면 이르게 탐지한 것처럼 부풀려집니다.

사건 평가와 오경보 분모

과제 2는 과거 학습 → 이후 설정 → 더 이후 평가의 순서를 지킵니다. 같은 사고의 주변 구간을 양쪽에 나누지 않습니다. 사고 주변을 양성으로 정해도 실제 이상 시작의 정답은 아닙니다. 현재 시점의 과거만으로 점수·경보를 만듭니다.

쉽게 말하면: 정상 평가 운항 200시간에 경보 5건이면 100시간당 2.5건입니다. 여러 연속 경보를 한 사건으로 셀지 먼저 정합니다. 0-1 점수와 경보 임계값을 구분하고, 같은 오경보 수준에서 사고 전 탐지율·선행시간을 비교합니다.

정식 평가의 F1 종류·비중·사고 전후 구간은 미확정입니다. 내부 F1로 대회 공식 평가를 대체하지 않습니다. 사고별 탐지율의 표본 수와 미탐 사건도 함께 표시합니다.

CPU 크기 제어와 전처리 아이디어

[설계 제안] 입력 정보를 지키면서 불필요한 계산을 줄입니다. 아래 아이디어의 새로움·성능 향상은 아직 입증되지 않았습니다.



반복은 압축하되 원래 관측은 보존

같은 선 안의 연속 동일 좌표를 형상 계산용에서 압축하고 원본의 점 수·반복률을 남깁니다. 고정 미터 축척과 형상 정규화 축척의 표현도 비교합니다.

쉽게 말하면: 중복은 158쌍으로 많지만, 시각이 없어 정박 시간인지 장치 반복인지 단정할 수 없습니다. 거의 한 점인 항적을 크게 확대해 기동으로 꾸미지 않습니다. 품질 불량을 자동 정상 점수 0으로 처리하지 않습니다.

모델별로 줄일 손잡이

TabM은 폭·깊이·멤버 수, RealMLP는 폭·깊이·반복 학습, 트리는 잎 수·깊이·트리 수, DTE는 추정기 규모, CNN은 채널·블록 수·이미지 크기를 조절합니다. 한 번에 모든 축을 탐색하지 않습니다.

쉽게 말하면: 작은 후보에서 출발해 성능이 필요한 만큼만 키웁니다. WKT 파싱·기하 특징은 캐시하고, float32 저장은 지역 좌표 변환 뒤에 합니다. 외부 모델을 추가할 때도 전체 비용을 합칩니다.

“경량”은 실제 측정으로 판단

저장 파일 크기, 전체 추론 경로의 CPU 시간, 최대 메모리, 특징·이미지 생성 시간을 함께 측정합니다. 동일 노트북·처리 행 수·CPU 작업 수·첫 실행 준비 여부를 맞춰 기록합니다.

쉽게 말하면: 신경망 파일이 작아도 전처리가 오래 걸릴 수 있습니다. 임의의 MB 기준으로 합격시키지 말고, 같은 성능에서 더 빠른 안과 같은 비용에서 더 좋은 안을 비교합니다.

강화학습은 이번 네 안건의 핵심에서 제외

경보의 대기·관찰·발령을 선택하는 순차 환경, 행동 로그 또는 검증 가능한 보상 설계가 생기면 확장 후보입니다. 현재 샘플에는 이 조건이 없어 고정 경보 규칙보다 낫다고 주장할 수 없습니다. 대회용 시간별 연속 점수는 유지합니다.

실험 순서와 최종 선택 기준

[미실행 계획] 아래는 정식 데이터 수령 후 수행할 비교입니다. 이 보고서에는 학습 성능이나 CPU 실측 결과가 없습니다.

단계	고정할 조건 / 비교	채택 판단
0. 입력 점검	라벨별 선박 수·기간·좌표계·점별 시각·사고 연결·제출 키 확인.	입력 조건이 틀리면 해당 안건을 보류.
1. 분류 선택	같은 선박 분할·특징·시간 예산에서 LightGBM, TabM, RealMLP와 각 혼합 비교.	설정 검증의 F1·비용으로 선택하고 독립 평가에서 확인.
2. 이상 확장	분류기 고정. 전역 강건 기준·Isolation Forest·DTE·혼합 비교.	같은 오경보 수준의 사고 전 탐지·선행시간으로 ③ 선택.
3. 이미지 기여	동일 선박 분할에서 기하 단독 / 이미지 단독 / 결합 비교.	④가 개선되는 클래스와 CPU 추가 비용을 확인.
4. 크기 선택	채택한 조합의 작은 크기 후보만 비교하고 마지막 평가를 잠금.	성능과 비용의 타협을 팀이 설명할 수 있는 안 선택.

제거 실험으로 아이디어를 검증합니다

품질 특징, 절대 위치, 다중 축척, 혼합 모델을 하나씩 빼고 비교합니다. 성능 차이가 작거나 분할마다 방향이 바뀌면 개선을 확정하지 않습니다.

쉽게 말하면: 새 재료를 하나씩 빼 보아 그 재료가 도움이 됐는지 확인합니다. 최종 평가 결과를 본 뒤 다시 설정을 고르면, 새 독립 평가가 필요합니다.

비판적 검토 뒤 반영한 수정

① 네 안건을 같은 역할로 비교하지 않음. ② GIST의 입력·선종 불일치 명시. ③ TabM의 내부 앙상블과 서로 다른 알고리즘 혼합을 구분. ④ DTE의 0-1 점수를 사고 확률로 해석하지 않음. ⑤ 모든 추천을 검증 전 판단으로 표시.

팀 설명용 결론: 숫자 특징으로 ①·②를 먼저 비교 → 분류와 별도로 ③의 이상탐지 효과 확인 → 추가 이득이 있을 때만 ④를 넣습니다. 기존 단순 기준이 이기면 기준안을 선택합니다.

논문과 공식 구현의 확인 근거

학회 이름만으로 적합성을 판단하지 않고, 입력·대상·평가 조건을 본문에서 함께 설명했습니다.

[R1] ICLR 2025

TabM: Advancing Tabular Deep Learning with Parameter-Efficient Ensembling

저자 공식 구현 · 논문 결과와 현재 제안의 차이를 본문에 표시했습니다.

[R2] NeurIPS 2024

Better by default: Strong pre-tuned MLPs and boosted trees on tabular data

저자 공식 구현 · 논문 결과와 현재 제안의 차이를 본문에 표시했습니다.

[R3] ICLR 2024

On Diffusion Modeling for Anomaly Detection

저자 공식 구현 · 논문 결과와 현재 제안의 차이를 본문에 표시했습니다.

[R4] AAAI 2025 · AI for Social Impact 기술 트랙

GIST: Gear Type Identification by Spatiotemporal Trajectory Transformation for Monitoring Fisheries

논문 본문·입력 표현·대상 선종·실험 조건을 확인했습니다.

구현과 검증의 공식 문서

[S1] 선박 그룹 분할 / F1 / Isolation Forest와 이상탐지
[S2] Shapely: WKT와 선 구조 / NumPy: 숫자 표현 간격
[S3] LightGBM: 모델 복잡도와 학습 제어

> **자료의 역할**
> 공지 이미지 3종과 제공 CSV는 과제·입력의 근거입니다. 논문은 방법과 연구 결과의 근거이며, 1-4순위와 조합 설계는 이 보고서의 판단입니다. 학회 간 서열이나 우리 대회에서의 성능 우위를 뜻하지 않습니다.

검토 기준일: 2026.10.14. 논문 링크와 구현 링크는 클릭할 수 있습니다. 정식 데이터의 상세 평가 규칙·제출 키·사고 평가 구간은 아직 확인되지 않았습니다.

기존 모델 가이드에서 바뀐 부분

별도 변경 기록 · 이전 통합 모델 가이드와 NeurIPS 근거 가이드의 내용을 이번 13쪽 보고서로 재구성했습니다.

기존 내용 / 보완 필요점	이번 보고서의 수정·압축	위치
NeurIPS 후보가 여러 개여서 선택 기준이 분산됨.	대표를 RealMLP로 한정. TabM·DTE·GIST를 더해 네 안건의 실행 순서와 서로 다른 역할을 표시.	1·3-7쪽
RealMLP 중심의 주력 연구안.	TabM을 먼저 검증하는 안으로 제시하되 RealMLP와 같은 조건에서 비교. 실측으로 순위 변경 가능.	3·4·11쪽
이미지 전환 및 이미지 모델 후보가 넓게 제시됨.	GIST 원 입력은 속도·방향 변화 분포임을 명시. 현재 WKT 형상 CNN은 참고 수정안이며 대상 선종 차이도 설명.	2·6쪽
최근 이상탐지 후보와 연속 이력 조건이 분산됨.	DTE를 숫자 특징 이상탐지 확장으로 집중. 표준화·정상 혼입·점수 변환·전역 경로 조건을 한곳에 정리.	5·7쪽
많은 알고리즘·표현·튜닝 선택지를 상세히 설명.	TabDPT·UniTraj·ScatterAD·EfficientFormer의 세부안과 긴 구현 설명은 분량을 위해 제외. 부적합으로 확정한 것은 아님.	본 보고서 범위
과적합·지표·전처리·크기 설명이 긴 문서에 분산됨.	선박 분할·시간 가용성·F1 예시·CPU 측정·품질 분리를 공통 절차로 묶고 기술 설명 아래 쉬운 해설 배치.	8-11쪽
강화학습의 상세 확장 가능성.	필요 환경과 보상 조건만 유지. 지금의 모델 선정 범위에서는 우선순위를 낮춤.	10쪽

계속 유지한 조건

점별 시각을 만들지 않음 / 구성 선 경계 유지 / 위치 정밀도 보존 / ID는 분류 입력 제외 / 정상과 품질 문제 구분 / 신규 선박·사건 단위 평가 / 공식 규칙 우선. 원본 문서는 수정하거나 덮어쓰지 않았습니다.

이 문서는 알고리즘 선정 회의와 팀 설명을 위한 통합 요약입니다. 참가신청서 문안은 대상이 아니며, 구현을 완료하거나 성능을 검증했다는 보고서가 아닙니다.