조업형태 분류 모델 — 알고리즘 추천 정리

작성 2026-10-14 (수) · 작성 Claude
근거: 대회 공지·샘플 10행·공개 연구/공식 문서
문제해결 마감 11.06까지 **D-23**

근거 논문·공식 문서·공지에 적힌 내용 추론 작성자 판단 — 실험으로 확인 필요 제안 작성자 제안

※ 샘플 10행으로는 어떤 알고리즘의 성능도 검증할 수 없음. 최종 선택은 전체 데이터 비교 실험 후 확정

0. 결론

모델을 최신에 개발된 알고리즘을 바탕으로 짜보고 싶었음
고전적이더라도 필수적인 알고리즘은 함께 포함하여 앙상블 구조로 만드려고함

한 문장 요약 제안

선박(또는 선박-일) 단위 특징표를 중심에 두고, 이미지와 점 시퀀스를 보조 입력으로 붙여 겹쳐 쌓는(스태킹) 앙상블.

· 중심 모델: 최신 표 형식 파운데이션 모델 **TabICLv2** (2026.02) · 꼭 함께 쓸 모델: **LightGBM / CatBoost**
· 보조: 이미지 → **DINOv3** 고정 특징 (2025.08), 점 시퀀스 → **MantisV2** 임베딩 (2026.02)
· 결합: 교차검증 바깥 예측(OOF)만으로 스태킹 → 온도 보정(제출 양식의 '확률' 대응)

1. 데이터 구조가 모델 선택을 결정한다

데이터 특성	근거	모델 설계에 주는 의미
정답은 선박 단위로 붙어 있는데 입력은 1시간 조각	공지, 샘플	레코드를 하나씩 분류하기보다 **선박 단위로 묶어서 판단**해야 함
자정 시간대 샘플 10행 중 8행이 사실상 정지	샘플 분석	1시간 조각 하나에는 모양 정보가 거의 없음 → **집계가 필수**
점마다 시각이 없음	공지	시퀀스 모델은 '점 순서'만 쓸 수 있음. 실제 속력은 만들 수 없음
Test A는 학습에 없는 새 선박	공지	같은 배가 학습과 검증에 동시에 들어가지 않게 나눠야 함
선박 수는 수천 척 수준일 가능성	추론	적은 표본에 강한 모델이 유리 → 표 형식 파운데이션 모델이 잘 맞음

2. 추천 구성 제안

공통 입력
WKT 문자열
↓ 숫자 좌표 파싱
↓ 미터 단위 변환
↓ 파트(조각)별 분리 유지

A · 핵심
특징표
선박 단위 통계 특징
→ **TabICLv2**
+ LightGBM / CatBoost
(+ RealMLP / TabM)

B · 보조
이미지
선박-일 항적 그림
(고정 축척, 다중 축척)
→ **DINOv3** 고정 특징
→ 간단한 분류기

C · 보조
시퀀스
점 순서 시퀀스
(이동량·회전각)
→ **MantisV2** 임베딩
/ MultiRocket-Hydra

▼ A · B · C 의 OOF 확률

결합: 교차검증 바깥 예측(OOF)만으로 스태킹 → 간단한 메타 모델(로지스틱 회귀 수준) → 온도 보정 → 제출(예측 조업형태 + 확률)

A를 핵심으로 둔 이유 추론 — 위치(어디서)·시간대(언제)·움직임(어떻게)을 모두 담을 수 있는 유일한 경로. 이미지는 시간대를 잃고, 시퀀스는 위치를 잃는다.

3. 최신 알고리즘 추천

역할	알고리즘 (발표 시점)	추천 이유 근거	주의할 점
A 핵심	**TabICLv2** (2026.02)	학습 없이 예시를 보고 바로 예측하는 표 형식 파운데이션 모델. 논문은 튜닝 없이 TabArena(표 데이터 공개 벤치마크)·TALENT 1위라고 주장. 저장소에 "관대한 라이선스"라고 명시	정확한 라이선스 이름과 결측값 처리 방식은 직접 확인 필요
A 후보	TabPFN-2.6 (2026.04) / TabPFN-3 (2026.05)	TabArena 리더보드 v0.1.4에서 단일 모델 1·2위	**비상업 라이선스.** 상금이 있는 대회이고 수상 시 코드 공개 의무 → 주최측·Prior Labs 확인 필요
A 다양성	RealMLP, TabM (ICLR 2025)	처음부터 학습하는 신경망 중 최상위권. 트리 모델과 오차 패턴이 달라 앙상블에 유리	표준화와 튜닝이 필요

역할	알고리즘 (발표 시점)	추천 이유 근거	주의할 점
B	**DINOv3** (Meta, 2025.08) 고정 특징	가중치를 고정하고 중간층 특징만 쓰면 적은 데이터로도 과적합이 적음. 사전학습 ViT 중간층이 시계열 분류에 강하다는 연구(TiViT, 2025)	224×224 3채널 입력. 정확한 라이선스 조건 확인 필요
C	**MantisV2** (2026.02)	시계열 분류 전용 경량 파운데이션 모델(수백만 파라미터). 임베딩만 뽑아 쓸 수 있음. 코드는 Apache 2.0	길이 512(32의 배수)로 맞춰야 하고, 채널은 각각 따로 인코딩됨

참고할 만한 연구 결과 근거

- **TiViT (2025)**: 이미지 계열 표현 + 시계열 파운데이션 모델을 합치면 단독보다 좋음 (UCR 기준 Mantis 80.1 → 합성 83.0). → B와 C를 함께 쓰는 근거
- **GIST (AAAI 2025)**: 항적을 고정 크기 이미지 비슷한 형태로 바꾼 뒤 CNN으로 어구 3종 분류, 정확도 97% 보고. 검증 분할 방식은 공개 요약에서 확인 못 함

추천하지 않는 것 추론

- **궤적 파운데이션 모델**: 2025년 서베이의 모델들은 도로망 GPS용이고 시각 정보를 쓰는 것으로 기술됨. 해양용 모델은 없었음
- **대형 Transformer를 처음부터 학습**: 선박 수가 적으면 과적합 위험이 큼
- **LLM이 WKT 문자열을 직접 읽는 방식**: 5절 참고

4. 최신은 아니어도 꼭 넣었으면 하는 것

알고리즘	이유
LightGBM / CatBoost	결측값을 그대로 처리하고 빠르며 해석이 쉬움. TabArena에서도 파운데이션 모델 바로 아래 수준. **앙상블의 안전장치이자 비교 기준**
MultiRocket-Hydra (2023, aeon)	시퀀스 브랜치의 빠르고 강한 기준선. Mantis가 쓸 만한지 판단하는 비교 대상
Attention-MIL 풀링 (2018)	선박 하나를 '시간 조각들의 묶음'으로 보고, 의미 있는 조각(조업 중인 시간)에 가중치를 줌. 정지 레코드가 많은 이 데이터와 구조가 잘 맞음
OOF 스태킹 + 온도 보정	여러 모델을 결합할 때 과적합을 막는 표준 절차. 제출 양식에 '확률'이 있으므로 보정이 필요

5. 문자열 vs 이미지

문자열을 그대로 쓰는 것 — 비추천 추론

- LLM이 WKT 텍스트를 읽으면 좌표 숫자가 임의로 토큰 단위로 잘림
- 126점짜리 레코드 하나가 수천 토큰 → 비용 대비 근거 없음
- 이 과제에서 효과적이라는 연구 근거를 찾지 못함

문자열은 숫자로 파싱하는 것이 필수이고, 파싱한 좌표가 A·C 브랜치의 입력이 된다.

이미지 변환 — 유용하지만 조건이 있음

변환 방식	이동 중	정지	판단
② 모양 정규화	모양 잘 보임	**1~3 m GPS 잡음이 모양처럼 부풀려짐**	**단독 위험**
③ 고정 축척 (25 m/px)	실제 크기	점 하나	**크기 보존**
④ 다중 축척 3채널	세밀+큰 흐름	점	**추천**

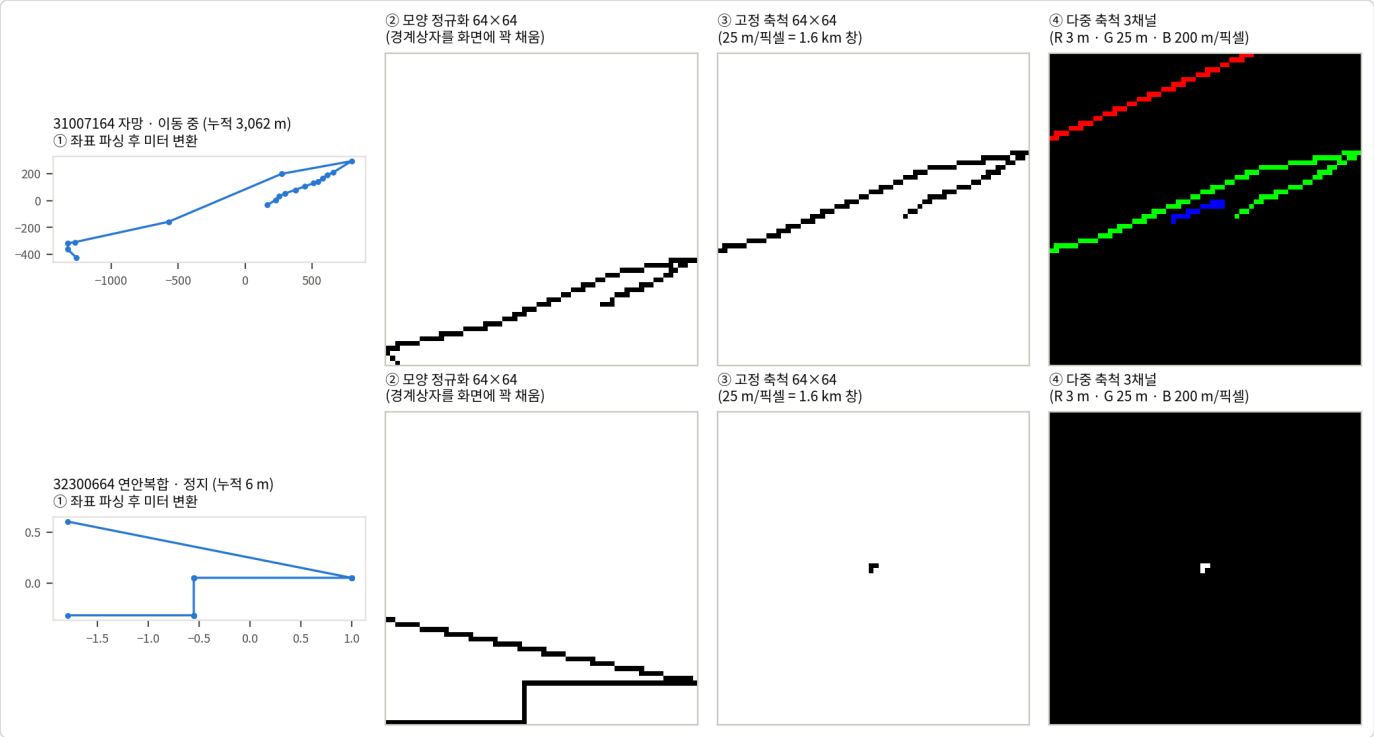


그림 1. 샘플 2건(31007164 자망·이동 / 32300664 연안복합·정지)을 네 가지 방식으로 변환한 결과. 정지 선박을 모양 정규화하면 수 m 잡음이 화면 전체에 그려져 실제 조업 궤적과 구별되지 않는다.

이미지 브랜치 권장 방식 제안

1시간 레코드가 아니라 **선박-일 단위로 모아서, 고정된 물리 축척 여러 개**(예: 3 m · 25 m · 200 m/픽셀)로 그린다. 그림에 담기지 않는 실제 크기와 시간대는 A 브랜치의 특징으로 보완한다.

6. 알고리즘을 쓰기 위한 필수 조건

공통 전처리 (모든 브랜치의 전제 조건)

1. `utf-8-sig` 로 CSV를 읽고, 이름 없는 빈 열 7개를 제거
2. WKT 파싱(shapely). 좌표 순서는 **경도, 위도**, 파트는 분리된 채로 유지
3. 미터 단위로 투영(EPSG:5179 또는 국소 평면). 도 단위 숫자를 그대로 거리로 쓰지 않음
4. 연속 중복 점 정리, 정지 판정 임계값 결정 — 샘플에서 일부 좌표가 **약 18 m 격자**로 기록되어 있으므로 그 이상
5. `fishing_code` 한글 문자열을 정수 번호로 바꾸고 대응표 저장

알고리즘별 조건

알고리즘	입력 형태	필수 조건	제약
TabICLv2 / TabPFN	숫자 표 (선박 단위 1행)	학습 행 수·특징 수가 한도 이내	TabICLv2: 약 10만 행·2,000특징까지 성능 양호 명시. TabPFN-2.6: 10만 행·2,000열·10클래스. GPU 권장
LightGBM / CatBoost	숫자 표	스케일 조정 불필요, 결측값 그대로 사용 가능	클래스 불균형 시 가중치 필요
RealMLP / TabM	숫자 표	**각 학습 폴드 안에서만** 표준화·결측 대치	하이퍼파라미터 튜닝 필요
DINOv3	224×224 RGB 이미지	ImageNet 평균·표준편차로 정규화, 고정 축척으로 래스터화	가중치 고정 + 중간층 특징 + 간단한 분류기
MantisV2	1채널 시퀀스, 길이 512	점 순서·호 길이 기준 리샘플링. **시간 기준 리샘플링 금지**(시각이 없음)	파트 경계를 넘어 잇지 말 것. 채널은 각각 인코딩
MultiRocket-Hydra	같은 길이 시퀀스	패딩 또는 리샘플링	CPU로도 빠름
Attention-MIL	선박별 레코드 임베딩 묶음	묶음 크기가 달라도 처리하도록 마스킹	레코드 임베딩을 먼저 만들어야 함
스태킹	각 모델의 OOF 확률	**모든 기본 모델이 같은 폴드 분할 사용**	메타 모델은 로지스틱 회귀 정도로 단순하게

A 브랜치 특징 예시 (외부 데이터 없이 계산 가능) 제안

그룹	특징
위치	주 정박 위치(가장 많이 정지한 지점), 정박지에서 최대 거리, 조업 위치 분포의 반경
시간	24시간 활동 분포, 하루 활동 시간 수, 출항부터 입항까지 길이
움직임	레코드당 이동량의 분위수, 정지 비율, 직선성, 회전각 통계, 같은 격자 칸 재방문율
품질	점 수, 파트 수, 좌표 정밀도 — **수집 장비 차이를 외울 위험**(팀원 교재 19장 경고) → 넣은 버전과 뺀 버전을 반드시 비교

※ '레코드당 이동량'은 실제 속력이 아니라 시각 없이 계산되는 양이라 "속력 계산 금지"라는 팀 원칙과 충돌하지 않는다.

7. 과적합 방지 체크리스트

#	규칙	이유·근거
1	**StratifiedGroupKFold (그룹 = rfid_id)**	같은 배가 학습·검증에 동시에 들어가면 안 됨. 2025년 Sci Rep 어선 분류 논문: 무작위 10-fold 교차검증 98.3% → 이듬해 데이터 독립 테스트 91.9% 근거
2	정규화·결측 대치·특징 선택·앙상블 가중치를 **모두 학습 폴드 안에서만**	검증 점수 부풀림 방지
3	스태킹은 OOF 예측으로만, **한 번도 쓰지 않은 선박 그룹**을 최종 확인용으로 보존	선택 과정 자체에 대한 과적합 방지
4	선박마다 같은 가중치	정지 레코드가 많은 선박이 학습을 지배하지 않도록
5	정박지 권역 단위로 묶은 교차검증으로 위치 의존도 점검	성능이 크게 떨어지면 '지역을 외운 모델'
6	이미지·시퀀스 백본은 **고정**, 간단한 분류기만 학습	미세조정은 선박 수가 충분할 때만
7	증강은 모양 이미지에만 (회전·반전, 점·파트 무작위 제거, 약 18 m 지터)	지리 좌표 이미지는 증강 금지 — 위치 의미가 바뀜
8	여러 seed로 반복해 평균·분산 보고	가장 좋은 seed 하나만 고르면 선택 편향

8. 남은 23일 안의 순서 제안 제안

기간	할 일
1주차	데이터 확보 → 파싱 → A 특징 → **LightGBM 기준선 + TabICLv2**
2주차	B(DINOv3 고정 특징), C(MultiRocket-Hydra → MantisV2) 추가 → 각각 A 단독보다 나은지 OOF로 비교
3주차	실제로 도움이 된 브랜치만 남겨 스태킹 → 온도 보정 → 최종 확인용 선박 그룹으로 평가

채택 기준

이미지 브랜치와 시퀀스 브랜치는 **A 단독보다 나아진다는 OOF 근거가 있을 때만** 남긴다. 라이선스(TabPFN 비상업, DINOv3 조건)는 사용 전에 확인한다.

참고 자료

- TabICLv2 — arxiv.org/html/2602.11139 · github.com/soda-inria/tabicl
- TabPFN 모델·라이선스 — docs.priorlabs.ai/models · huggingface.co/Prior-Labs/tabpfn_2_6
- TabArena — arxiv.org/pdf/2506.16791 · 리더보드 요약 codesota.com/tasks/tabular-ml
- TabM (ICLR 2025) — arxiv.org/abs/2410.24210
- MantisV2 — arxiv.org/html/2602.17868v1 · github.com/vfeofanov/mantis
- TiViT — arxiv.org/html/2506.08641v2
- DINOv3 — ai.meta.com/blog/dinov3-self-supervised-vision-model
- GIST (AAAI 2025) — ojs.aaai.org/index.php/AAAI/article/view/35056
- Kim & Lee 2020 (한국 AIS 어구 분류) — mdpi.com/2076-3417/10/11/4010
- Sci Rep 2025 어선 분류 — nature.com/articles/s41598-025-88158-2
- 궤적 파운데이션 모델 서베이 — arxiv.org/html/2511.20729
- aeon 합성곱 기반 분류 — aeon-toolkit.org (convolution_based)