2026 DATA·AI 분석 경진대회 · 문제해결 부문

어선 항적 과제 이해 가이드

***3.문제배경
이 부분부터 확인하는걸 추천

조업형태 판별(과제 1)과 이상항적 탐지(과제 2)를 위한
대회 구조 · 데이터 의미 · 샘플 분석 · 접근 전략 정리

작성일	2026년 10월 12일 (월) — 문제해결 마감(11.06)까지 **D-25**
근거 자료	대회 포스터, 공지 이미지 3장(문제 개요·목표·데이터 설명), 2026_참가신청서.hwp, 어선 과제 샘플데이터.csv(10행), 공개 문헌 일부(부록 출처 참고)
작성	Claude (참가자 학습용 정리 자료이며 주최측 공식 문서가 아님)

이 문서의 표기 규칙 — 정보의 확실성 수준을 구분합니다

- 공지 — 포스터·공지 이미지·참가신청서에 **문자 그대로 적혀 있는 내용**입니다.
- 데이터 — 샘플 CSV를 **직접 계산·분석한 결과**입니다. 단, 10행뿐이라 전체 데이터에 일반화할 수 없습니다.
- 추론 — 위 근거로부터 **작성자가 추론한 내용**입니다. 사실처럼 받아들이지 말고 실제 데이터나 주최측 문의로 확인해야 합니다.
- 제안 — 작성자의 **방법론·진행 방식 제안**입니다. 정답이 아니라 출발점입니다.

목차

1. 한눈에 보기 — 이 대회에서 해야 할 일
2. 대회 구조 — 부문, 일정, 시상, 평가, 신청서
3. 문제 배경 — V-Pass와 이 과제가 나온 이유
4. 데이터 이해 — 한 행의 의미, 컬럼, WKT, 좌표와 시간의 한계
5. 샘플 데이터 분석 결과
6. 과제 1 상세 — 조업형태 판별
7. 과제 2 상세 — 이상항적 탐지
8. 제출물 정리
9. 주최측에 확인해야 할 질문
10. 남은 25일 진행 로드맵
11. 부록 — 용어 정리, 출처, 코드 예시

※ 대회 규정상 제공 데이터는 승인 목적 외 사용·제3자 제공이 금지됩니다 공지 . 이 문서에는 샘플 10행에서 계산한 요약값만 담았습니다.

1. 한눈에 보기 — 이 대회에서 해야 할 일

과제2는 테스트 데이터를 넣어서
얻은 결과를 제출하는 것

한 문장으로 요약하면, **"어선의 시간대별 이동 경로(항적)만 보고 ① 그 배가 어떤 방식으로 조업하는 배인지 맞히고, ② 사고와 관련된 이상한 움직임을 시간대별 점수로 표시하는 것"**입니다. 같은 항적 데이터로 성격이 다른 두 문제를 풉니다.

구분	과제 1. 조업형태 판별	과제 2. 이상항적 탐지
문제 유형	다중 클래스 **분류** (지도학습)	**이상 탐지** (사고 라벨이 적어 사실상 비지도·약지도) 추론
학습 정답	Train의 `fishing_code` 공지	정답 라벨 없음. 일부 사고 선박의 ID·사고 발생시각만 별도 제공 공지
평가 데이터	**Test A** — fishing_code 제거, **Train에 없는 신규 선박** 공지	**Test B** — 정상구간과 사고 관련 구간이 포함된 시간대별 항적 공지
출력	예측 조업형태 + 그 확률(0~1)	시간대별 이상항적 점수(0~1)
평가 기준	공지에 지표 명시 없음 — 확인 필요	실제 사고시각 기준으로 사고 전·후 이상징후를 **얼마나 정확하고 조기에** 탐지하는지 공지
핵심 난점	처음 보는 배에 대한 일반화, 정지 상태 레코드가 많을 가능성	"이상 = 사고"가 아님, 사고 사례 극소수, 조기 탐지와 오탐의 균형

꼭 기억해야 할 다섯 가지

1. **한 행 = 한 선박 × 하루 × 1시간의 이동 경로 조각**입니다. 선박 단위 정답을 시간 조각 단위 입력에서 맞혀야 하는 구조입니다. 공지
2. **Test A는 학습에 없는 배**로 구성됩니다. 같은 배가 학습·검증에 동시에 들어가면 점수가 부풀려지므로 **선박 ID 단위로 나눈 교차검증**이 필수입니다. 공지 제안
3. **항적 안의 각 점에는 시각 정보가 없습니다.** "시간대(0~23시)"만 있으므로 속도·가속도는 가정을 둔 **추정치**일 수밖에 없습니다. 데이터
4. 과제 2는 사고 정보가 **일부 선박**에만 주어지므로, "평상시 패턴을 학습하고 벗어난 정도를 점수화"하는 접근이 기본이 됩니다. 공지 추론
5. **평가지표, 예측 단위(제출 양식의 '파일명' 의미), 클래스 목록 확정 여부**가 공지에 불명확합니다. 9장의 질문 목록으로 주최측에 확인하는 것이 좋습니다.

2. 대회 구조

2.1 기본 정보 공지

대회명	2026 DATA·AI 분석 경진대회 — "데이터와 AI 기반의 사회·과학 문제 해결을 통해 국내 연구데이터 생태계 저변을 확대"
전체 기간	2026.08.11(화) ~ 11.25(수)
플랫폼	DataON 경진대회 플랫폼 (dataon.kr/competition), AIDA
주최/주관	과학기술정보통신부, 국가과학기술연구회(NST), 국회도서관, 대전광역시, 해양경찰청, 한국수자원공사, 대전 중구, 한국과학기술정보연구원(KISTI) / 후원: (사)한국콘텐츠학회
문의	경진대회 운영사무국 aidatacon@gmail.com

2.2 두 개의 부문 — 우리가 참가하는 곳은 '문제해결 부문'

부문	내용	참가자격
문제발굴	AI·데이터 분석으로 해결이 필요한 사회·과학 문제 및 데이터를 발굴	문제 해결이 필요한 기관이나 개인
문제해결	문제발굴 단계에서 선정된 공모 발굴문제 및 **수요기관이 제시한 정책지정 문제**를 해결하는 고성능 AI 모델 개발	데이터 분석·활용에 관심 있는 개인이나 팀

추론 **이 과제의 출처**

공지의 "경기도보다 넓은 관할 구역 내 수많은 어선을 인력에 의한 모니터링만으로 … 판별하는 데 어려움" 이라는 문구, V-Pass 관련 고시 인용, 포스터 주최기관과 시상 목록의 **해양경찰청**을 종합하면, 이 과제는 해양경찰(또는 산하 해양경찰서)이 수요기관으로 제시한 **정책지정 문제**일 가능성이 높습니다. 공지에 명시된 사실은 아닙니다. 이 추론이 맞다면, 심사에서는 모델 성능 외에 **해양경찰의 실제 모니터링 업무에 쓸 수 있는가**도 중요하게 볼 가능성이 있습니다.

2.3 일정과 남은 기간 공지

단계	날짜	비고	오늘(10.12) 기준
문제발굴	08.11 ~ 09.04	경진대회 플랫폼	종료
채택 문제 공개	09.15	경진대회 플랫폼	종료
데이터 업데이트	09.28	1월 rfid_time 오류값 및 4월 중복 행 수정	완료
문제 해결	**09.15 ~ 11.06(금)**	분석·제출 기간	**D-25**
문제별 후보 선정	11.09 ~ 11.13	**서류 평가**	D-28 ~ D-32
최종 발표평가 / 시상	11.25(수)	KISTI 대전본원 키움관	D-44

즉시 확인할 것

09.28 데이터 업데이트(1월 `rfid_time` 오류값, 4월 중복 행 수정) **이전에** 데이터를 내려받았다면 다시 받아야 합니다. 이 공지는 학습 데이터에 **최소 1월과 4월 자료가 포함**되어 있음을 보여줍니다 **추론** . 정확한 기간·규모는 실제 데이터로 확인하세요.

2.4 시상 — 문제해결 부문 공지

상장	수상	시상 내역	상금
대상	1팀	국회의장상	300만원
최우수상	1팀	과학기술부총리상	200만원
우수상	5팀	국회도서관장상, 대전광역시장상, **해양경찰청장상**, 한국수자원공사 사장상, 대전중구청장상	각 100만원

※ 포스터 기준 대회 전체 총상금 1,300만원, 11개 팀 선발(문제발굴 부문 포함). 발굴 문제 수와 해결 방법의 우수성에 따라 수상팀 수는 바뀔 수 있고, 우수 수상자에게 학술대회 발표 기회가 주어집니다.

추론 우수상의 시상 기관이 주최기관들과 일치하므로, 각 우수상이 해당 기관이 낸 문제와 연결되어 있을 수 있습니다(예: 어선 과제의 최우수 팀 → 해양경찰청장상). 확정된 사실이 아니므로 기대치 설정에만 참고하세요.

2.5 평가가 어떻게 이루어지나

- 공지 문제별 후보 선정은 **서류 평가**(11.09~11.13), 최종은 **발표 평가**(11.25)입니다. 심사 점수는 비공개이며 이의 제기가 불가합니다(신청서 규정 4).

- 공지 과제 2는 “별도로 보유한 실제 사고 발생시각을 기준으로 사고 전·후 이상징후를 얼마나 정확하고 조기에 탐지하는지”로 평가합니다.
- 추론 서류·발표 평가 구조이므로 리더보드 점수 하나만으로 순위가 결정되기보다, **정량 성능 + 방법론의 타당성 + 설명 가능성 + 실무 활용성**을 종합적으로 볼 가능성이 높습니다. 따라서 “왜 이 피처가 이 조업형태를 구분하는가”를 근거와 함께 설명할 수 있는 모델이 유리할 수 있습니다.

2.6 참가신청서 구성과 주의할 규정 공지

신청서(hwp)는 ① 개인정보 수집·이용 동의, ② 경진대회 규정 서약, ③ 참가자 정보·서명, ④ **문제해결 제안서**로 구성됩니다. 제안서에는 문제명, 팀명, 제안 제목, 제안 요약, 그리고 자유 서식의 제안 내용(**1. 데이터 활용 방안 및 분석 방법론, 2. 추진일정(계획), 3. 예상 결과물**)을 씁니다. 제출 기한은 이 자료들에 나오지 않으므로 플랫폼에서 확인하세요.

규정	분석 작업에 주는 의미
데이터 목적 외 이용·제3자 제공·대여·판매 금지	팀원 외 공유 금지. 공개 저장소(GitHub 등)에 원본 데이터를 올리면 안 됩니다.
개인 식별 형태로 변경 금지, 재식별 가능성 시 이용 중지·통지·폐기	선박 ID를 외부 선박 DB와 결합해 실제 선박을 특정하는 시도는 피해야 합니다.
대회 종료 후 제공 데이터 폐기	대회 후에도 포트폴리오로 쓰려면 데이터 없이 코드·요약 결과만 남기는 방식을 고려해야 합니다.
저작권 문제가 해결된 데이터·도구만 사용	외부 데이터(해안선, 수심, 기상 등)나 사전학습 모델은 라이선스를 확인해야 합니다.
수상자는 최종 제출물·코드·문서를 DataON/AIDA에 공개하는 데 동의	처음부터 재현 가능하고 읽기 좋은 코드로 정리해 두는 편이 좋습니다.
잠재 수상자 통지는 이메일, 1주일 내 무응답 시 차순위로 양도 가능	신청서에 적은 이메일을 꾸준히 확인해야 합니다.
타 행사 수상작이거나 지적재산권 침해 시 수상 취소·상금 회수	다른 대회 결과물을 재활용할 때 주의가 필요합니다.

3. 문제 배경 — V-Pass와 이 과제가 나온 이유 <여기서부터 보는 것을 추천>

3.1 공지가 설명하는 배경 공지

- 어선은 어업 종류와 조업 방식에 따라 서로 다른 항적 패턴을 보이며, 이 특성은 선박 위치정보를 통해 데이터로 수집되고 있습니다. 근거 법령으로 「어선법」 제5조의2(어선위치발신장치)와 「선박패스(V-Pass) 장치 등의 설치기준 및 운영 등에 관한 고시」 제9조가 제시되어 있습니다.
- 관할 해역이 경기도보다 넓어, 수많은 어선을 사람이 모니터링해서는 사고·불법조업을 빠르게 판별하기 어렵습니다.
- 조업방식별 항적 패턴을 학습하고 시간대별 항적과 비교하면, 평상시와 다른 이동 양상을 찾아 사고 관련 이상징후를 조기에 탐지할 수 있다는 것이 문제의 출발점입니다.

3.2 V-Pass(선박패스)란

V-pass의 특징과 현재의 어려움을 우리가 설계한 모델로 보완해줄 수 있다라는 점을 나중에 보고서(혹은 부가적인 설명내용)에 써도 좋을 것 같다고 생각됨

V-Pass는 어선의 위치를 자동으로 발신하는 어선위치발신장치의 한 종류로, 어선에 설치되어 해양경찰 측 육상 수신국으로 위치를 보냅니다. 공개 연구(Journal of Marine Science and Engineering, 2023)에 따르면 다음과 같은 특징이 있습니다.

- 단말의 SOS 버튼을 누르거나 안테나가 분리되면 해양경찰 상황실로 경보가 전송됩니다.
- 자동 출입항 신고 시스템과 연동되어, 파출소 방문 없이 출항·입항 신고가 가능합니다.
- 해당 연구의 실험에서는 단말이 30초 간격으로 위치를 저장했고, 발신은 규정상 최대 10분 이내 간격을 지켰습니다.
- 같은 연구에서 약 4시간 동안 기대 패킷 480개 중 269개만 수신되어 **약 44%가 누락**된 사례가 보고되었습니다.

추론 **분석에 주는 함의**

위 연구는 특정 해역·특정 실험 조건의 결과이므로 이 대회 데이터에 그대로 적용된다고 볼 수 없습니다. 다만 **V-Pass 항적은 수신 누락 때문에 점 간격이 불균일하고 중간이 비어 있을 수 있다**는 점은 염두에 두어야 합니다. 이는 ① 속도 추정의 오차, ② MultiLineString이 여러 조각(파트)으로 나뉘는 현상, ③ 과제 2에서 "신호가 끊긴 것"이 사고 때문인지 단순 수신 누락인지 구분하기 어려운 문제로 이어질 수 있습니다.

3.3 두 과제가 어떻게 연결되어 있나 추론

이건 당연한 내용이라 건너뛰어도 됨
당연히 연결되는거지 ㅅㅂ

공지의 과제 2 설명에는 "선박별 **또는 동일 조업형태별** 평상시 항적패턴을 분석"한다는 표현이 있습니다. 즉 과제 1에서 만든 "조업형태별 정상 패턴"에 대한 이해가 과제 2의 비교 기준(baseline)이 되도록 설계된 것으로 보입니다. 예를 들어 통발 어선은 원래 짧은 이동과 정지를 반복하므로, 같은 움직임이라도 통발 어선에게는 정상이고 연승 어선에게는 이상일 수 있습니다. 따라서 두 과제를 별개로 풀기보다 **과제 1의 피처·모델을 과제 2에 재사용**하는 구조가 효율적입니다 제안 .

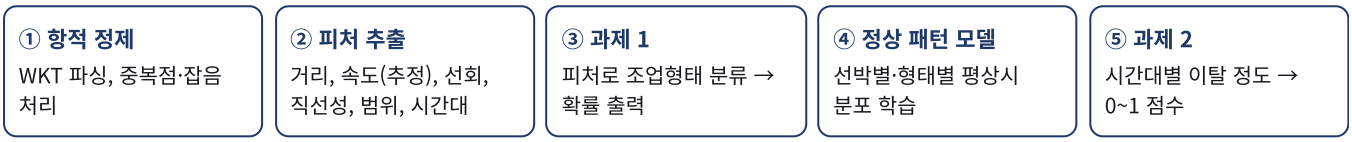


그림 1. 두 과제를 하나의 파이프라인으로 묶는 구성 예시 제안

4. 데이터 이해

4.1 한 행(레코드)이 의미하는 것

공지 "하나의 레코드는 특정 선박의 특정 일자·시간대 이동항적"입니다. 데이터의 계층을 위에서 아래로 그리면 다음과 같습니다.

선박 — `rfid_id` 로 식별. 조업형태(`fishing_code`)는 선박에 붙은 속성으로 보임 추론

일자 — `part_dt` (YYYYMMDD)

시간대 = 한 행 — `rfid_time` (0~23). 이 1시간 동안의 이동경로가 `geom` 한 칸에 들어 있음

MultiLineString 안의 LineString(파트) — 1시간 경로가 여러 조각으로 나뉠 수 있음

점 (경도, 위도) — 실제 위치 기록. **점마다 시각 정보는 없음**

이해를 돕기 위해, 한 척의 배가 하루 동안 만들어 내는 행들을 그려 보면 아래와 같습니다. **아래는 실제 데이터가 아니라 개념 설명용 가상 예시**입니다.

가상 예시 — 통발 어선 A의 하루 (각 칸 = 1시간 = 데이터 1행)



항구 정박(거의 정지) 어장까지 이동 조업(저속·반복 이동) 신호 누락 등으로 행이 없을 수 있음

이 경우 24개 행 중 조업형태를 드러내는 행은 5~6개뿐이고, 나머지 대부분은 "항구에 가만히 있는" 행입니다. 그런데 이 배의 모든 행에는 똑같이 `통발` 라벨이 붙습니다. 행 하나하나를 독립적으로 분류하면 정박 행이 큰 잡음이 되므로, **선박(또는 선박-일자) 단위로 묶어 판단**하는 것이 자연스럽습니다 추론 .

이미지로 설명해주는건 도움이 되서 좋은데, 당연히 선박 단위로 묶어서 판단해야지 ㅅㅂ 마지막 문장도 당연한 얘기

4.2 컬럼별 상세 설명

컬럼	공지 설명 공지	샘플 실제 값 데이터	분석 시 의미와 주의점
`part_dt`	연월일(YYYYMMDD). 해당 항적이 생성된 날짜	정수 `20250101` (10행 모두 동일)	월·요일·계절 피처로 파생 가능. 조업은 계절 영향이 크다고 알려져 있음(업종·계절별 어업활동 공간분포 차이를 보고한 연구가 있음). **공지 예시는 20260101, 샘플은 2025년**이라 실제 연도는 확인 필요.
`rfid_id`	선박 ID 식별값 (예: 3100****)	8자리 정수. 앞 4자리가 3100/3170/3200/3210/3220/3230으로 다양	Test A는 신규 선박이므로 **ID 값 자체를 피처로 쓰면 안 됨**. 앞자리가 지역·단말 종류 등을 뜻할 가능성은 있으나 근거 없음 추론 . 쓰려면 누설 여부 검토 필요.
`rfid_time`	시간대(0~23). 해당 항적의 시간 구간	10행 모두 `0` (자정~01시)	시간 해상도가 1시간이라는 뜻. 활동 시간대 분포(새벽 출항·야간 조업 등)는 조업형태 구분에 중요한 피처가 될 수 있음 추론 .
`geom`	시간대별 이동경로. MULTILINESTRING((경도 위도, …)) 형식	파트 1~6개, 점 2~126개	좌표 순서가 **경도(X) 먼저, 위도(Y) 나중**. 4.3~4.5절 참고.
`fishing_code`	자망, 통발, 저인망 등 실제 조업형태. Train에서만 정답 라벨로 제공	자망 4, 연안복합 4, 통발 1, 채낚기연승낚시 1	샘플 비율은 전체 분포를 대표하지 않음. 공지 표에는 “저인망”이 예시로 있지만 분류 목록 그림에는 4종만 있음 → 실제 고유값 확인 필요.

샘플 파일 형식 이슈 데이터

① 헤더 뒤에 이름 없는 빈 열이 7개 있습니다(`fishing_code,,,,,,,`). pandas로 읽으면 `Unnamed: 5 ~ 11` 열이 생기므로 제거해야 합니다. ② 파일이 **UTF-8 BOM**으로 저장되어 있어 `encoding="utf-8-sig"` 로 읽는 것이 안전합니다. 실제 Train 파일도 같은 형식인지 확인하세요.

4.3 WKT MultiLineString 읽는 법

WKT(Well-Known Text)는 점·선·면 같은 공간 도형을 사람이 읽을 수 있는 문자열로 적는 표준 형식입니다. `MULTILINESTRING` 은 “선(LineString) 여러 개의 묶음”입니다. 샘플의 `31007894` (연안복합) 행을 분해하면 다음과 같습니다 (좌표는 지면상 일부 자릿수만 표시).

```
MULTILINESTRING ( (128.433998 34.844332, 128.433998 34.844332, 128.433998 34.844165), (128.433832 34.844332, 128.433998 34.844165, 128.433832 34.844332, 128.433832 34.844165) )
```

- 파란 부분 = 첫 번째 LineString(점 3개), 주황 부분 = 두 번째 LineString(점 4개).
- 각 점은 `경도 위도` 순서이며 공백으로 구분됩니다. 점끼리는 쉼표, 파트끼리는 괄호로 구분됩니다.
- 같은 좌표가 연속으로 반복되는 경우(예: 첫 두 점)가 흔합니다. 배가 움직이지 않았는데 위치가 여러 번 기록된 것입니다.

추론 **왜 1시간 경로가 여러 파트로 나뉘는가**

공지는 파트 분리 기준을 설명하지 않습니다. 가능한 원인은 (a) 신호 수신이 끊겼다가 다시 이어진 경우, (b) 서로 다른 수신국·출처의 기록이 합쳐진 경우, (c) 원천 데이터를 시간대별로 가공하는 과정의 규칙 등입니다. 샘플 `31703261`은 6개 파트에 점 126개가 있지만 고유 좌표는 7개뿐이며, 첫 파트와 나머지 파트의 좌표 정밀도가 다릅니다(4.5절). 이는 (b)의 가능성을 시사하지만 확정할 수 없습니다. **파트 수, 파트 간 간격, 중복점 비율**은 그 자체로 피처나 데이터 품질 지표가 될 수 있습니다.

4.4 좌표를 거리(미터)로 바꾸기

경도·위도는 각도이므로 그대로 빼면 거리가 되지 않습니다. 대략적인 환산은 다음과 같습니다.

- **위도 1° ≈ 111 km** (어디서나 거의 일정)
- **경도 1° ≈ 111 km × cos(위도)** → 한국 해역(위도 약 33~38°)에서는 약 88~93 km. 예: 위도 35°에서 약 91 km
- 예시: 소수점 넷째 자리 0.0001°는 위도 방향 약 11 m, 경도 방향(35°N) 약 9 m입니다.

정확한 계산은 하버사인(Haversine) 공식을 쓰거나, 좌표를 미터 단위 투영좌표계(예: 한국 통합좌표계 EPSG:5179, UTM 52N 등)로 변환한 뒤 유클리드 거리를 쓰는 방법이 일반적입니다 제안 .

데이터 좌표의 소수부에 60을 곱하면 깔끔한 "분(′)" 값이 나옵니다. 예: 34.71062166…° → 34° 42.6373′. 즉 원천 데이터는 **"도 분.분분분분" 형식**으로 기록된 뒤 십진 도로 변환된 것으로 보입니다 추론 . 이는 좌표에 **정밀도 단위(격자)**가 있다는 뜻이고, 4.5절의 계단형 움직임을 설명합니다.

4.5 좌표 정밀도와 시간 정보의 한계

(1) 좌표 정밀도가 레코드마다 다르다 데이터

대부분의 레코드는 0.0001′(약 0.2 m) 단위까지 기록되어 있지만, `31007894` 전체와 `31703261`의 일부 파트는 **0.01′(위도 방향 약 18.5 m) 단위**로만 기록되어 있습니다. 그래서 실제로는 정지해 있어도 좌표가 18 m씩 "계단처럼" 튀며, 누적 이동거리를 단순 합산하면 과대평가됩니다(5장의 31007894: 누적 109 m, 시작-끝 직선거리 24 m). 추론 단말 종류나 수신 경로의 차이일 수 있습니다.

(2) 점마다 시각이 없다 데이터

각 점이 몇 분 몇 초에 찍혔는지 알 수 없으므로 **속도 = 거리 ÷ 시간**을 정확히 계산할 수 없습니다. 샘플 10행 중 6행이 1시간에 점 17~18개를 가지고 있어, 약 3~4분 간격으로 고르게 기록된다고 가정하는 것은 가능합니다 추론 . 그러나 점이 2개뿐인 행, 4개뿐인 행, 126개(중복 다수)인 행도 있어 이 가정이 항상 맞지는 않습니다.

제안 **시간 한계를 다루는 실용적 방법**

1. **시간 불변 피처 우선**: 직선성, 선회각 분포, 이동 범위, 경로 모양처럼 속도를 몰라도 계산되는 피처를 중심에 둡니다.
2. **1시간 단위 지표**: "이 시간대에 얼마나 이동했는가(m/h)"처럼 시간대 단위로만 정의된 값은 가정 없이 계산됩니다.
3. **균등 간격 가정은 보조로만**: 점 간격을 60분 ÷ (점 수 − 1)로 두는 "추정 속도"는 피처 하나로 쓰되, 점 수가 적거나 중복이 많은 행에는 신뢰도가 낮다는 표시(점 수 자체)를 함께 넣습니다.
4. **연속 시간대 이어붙이기**: 같은 선박의 같은 날 연속 시간대 행을 이어 하루 궤적을 복원하면 출항~입항 같은 긴 패턴을 볼 수 있습니다.

5. 샘플 데이터 분석 결과 데이터

샘플은 **2025-01-01 00시 한 시간대의 서로 다른 선박 10척**입니다. 규모가 매우 작으므로 아래 결과는 “데이터가 어떻게 생겼는지” 감을 잡는 용도이며, 조업형태별 특징을 결론 내리는 근거로 쓰면 안 됩니다.

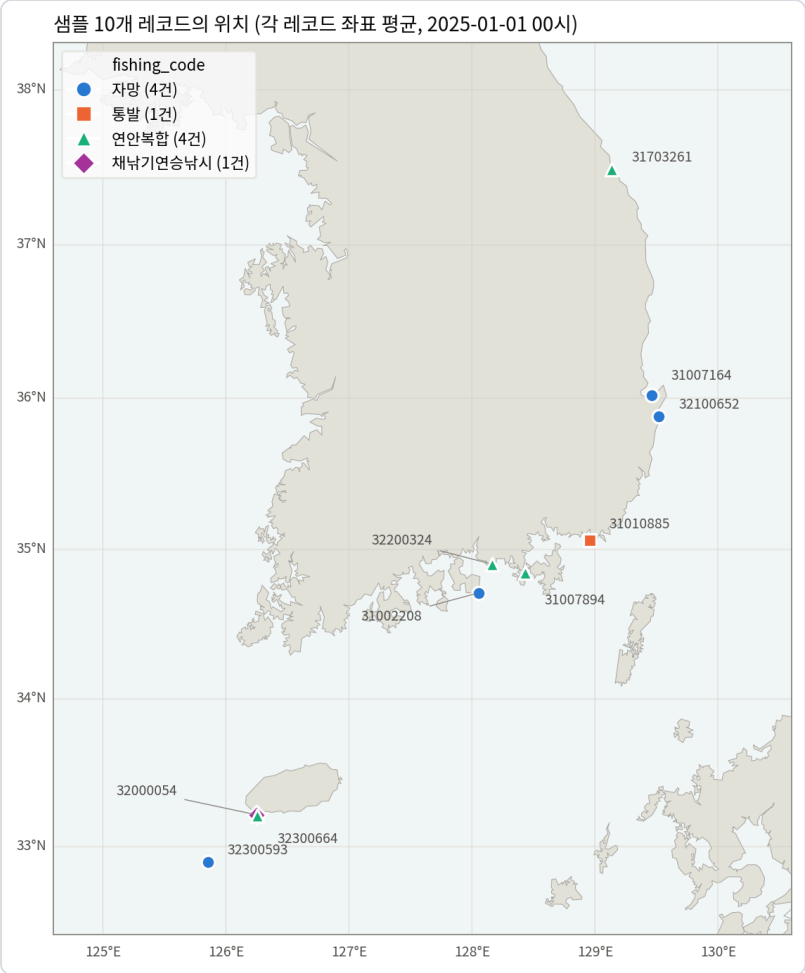


그림 2. 샘플 레코드의 위치(각 레코드 좌표의 평균). 제주 서남부의 32000054(채낚기연승낚시, ◆)와 32300664(연안복합, ▲)는 약 1 km 거리로 거의 겹쳐 있습니다. 해안선 데이터: GSHHS(basemap 패키지 내장, 중간 해상도).

rfid_id	조업형태	점(고유)	파트	누적거리	직선거리	직선성	이동범위(동서×남북)	대략 위치 추론
31007164	자망	18 (18)	1	**3,062 m**	1,476 m	0.48	2,115 × 723 m	포항 영일만 인근
32300593	자망	18 (18)	1	**177 m**	131 m	0.74	131 × 30 m	제주 남서쪽 약 50 km 외해
31703261	연안복합	126 (7)	6	149 m	10 m	0.07	9 × 18 m	강원 동해안
31007894	연안복합	7 (4)	2	109 m	24 m	0.22	15 × 19 m	경남 통영 인근
31002208	자망	4 (4)	1	25 m	12 m	0.49	6 × 15 m	경남 남해안
31010885	통발	2 (2)	1	8 m	8 m	1.00	7 × 4 m	부산 인근
32300664	연안복합	18 (5)	1	6 m	1 m	0.15	3 × 1 m	제주 모슬포 인근
32100652	자망	17 (5)	1	5 m	2 m	0.54	1 × 2 m	경북 동해안
32200324	연안복합	18 (6)	1	3 m	2 m	0.71	2 × 2 m	경남 남해안
32000054	채낚기연승낚시	18 (4)	1	2 m	2 m	0.71	1 × 1 m	제주 모슬포 인근

누적거리 = 인접 점 간 거리(하버사인)의 합(파트 사이 간격 포함). 직선거리 = 첫 점과 마지막 점 사이 거리. 직선성 = 직선거리 ÷ 누적거리(1에 가까울수록 곧게 이동). 위치 설명은 좌표를 지도에 찍어 본 작성자의 판단입니다.

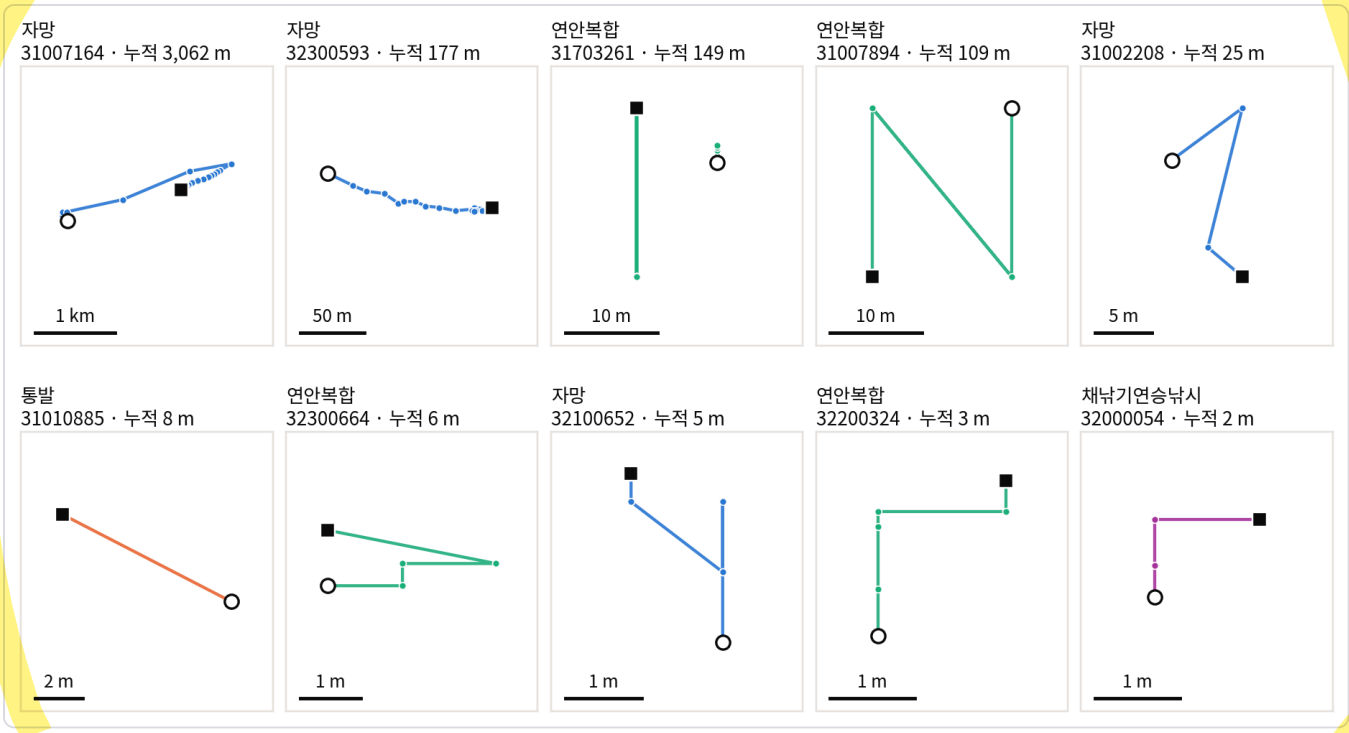


그림 3. 레코드별 항적 모양(◯ 시작점, ■ 끝점, 점 = 기록된 위치). 각 칸은 그 레코드에 맞춰 확대했으므로 **축척(왼쪽 아래 막대)이 칸마다 다릅니다**. 위 행 왼쪽 두 칸만 실제로 움직인 항적이고, 나머지는 수 m 안에서 흔들리는 정지 상태입니다.

5.1 관찰된 사실과 그 의미 ***여기 마음에 드는 생각거리들이 좀 있음***

1. **10척 중 8척은 사실상 정지 상태입니다.** 누적거리가 150 m 미만이며 그중 4척은 6 m 이하입니다. 자정 시간대라 항구나 연안에 정박해 있었을 가능성이 높습니다 추론 . 전체 데이터에서도 이런 "정보 없는 행"이 많다면, 행 단위 분류의 정확도에는 한계가 있고 선박 단위 집계가 중요해집니다.
2. **정지해 있어도 좌표가 흔들립니다(GPS 잡음).** 그림 3 아래 행처럼 1~3 m 안에서 지그재그가 생깁니다. 직선성이나 선회각을 그대로 계산하면 정지 선박이 "급선회를 반복하는 배"처럼 보일 수 있으므로, **일정 거리(예: 5~20 m) 미만 이동은 정지로 처리**하는 전처리가 필요합니다 제안 . 이런 방향성은 좀 생각해볼 필요가 있을듯
3. **좌표 격자 때문에 생기는 가짜 이동이 있습니다.** 31007894와 31703261은 18 m 단위로 좌표가 튀어, 누적거리가 직선거리의 4~14배로 부풀었습니다(4.5절).
4. **중복 점이 매우 많은 행이 있습니다.** 31703261은 점 126개 중 고유 좌표가 7개뿐입니다. 점 개수를 "활동량" 피처로 쓰면 왜곡됩니다.
5. **움직이는 자망 어선 31007164의 구간 거리 패턴**은 40~90 m가 반복되다가 718 m, 915 m, 529 m로 급증한 뒤 다시 40~80 m로 돌아옵니다. 점 간격을 약 3.5분(60분 ÷ 17)으로 가정하면 저속 구간은 약 0.4~0.8노트, 고속 구간은 약 5~8.4노트입니다 추론 . 저속 반복 구간은 어구를 올리거나 내리는 조업 행동, 고속 구간은 이동일 가능성이 있습니다 추론 . 이처럼 **"고속 이동 ↔ 저속 작업"의 전환 패턴**이 조업형태를 구분하는 핵심 정보가 될 수 있습니다. > 생각해볼만한 아이디어
6. **외해의 자망 어선 32300593**은 1시간 동안 177 m를 일정한 방향으로 아주 천천히 이동했습니다. 같은 가정에서 약 0.1노트 수준이며, 엔진을 쓰지 않고 표류하거나 어구 곁에서 대기하는 상황일 수 있습니다 추론 .
7. **샘플 클래스 비율(자망 4, 연안복합 4, 통발 1, 채낚기연승낚시 1)**은 10행에서 나온 것이라 전체 분포를 대표하지 않습니다. 실제 Train에서 선박 수 기준·행 수 기준 분포를 각각 확인해야 합니다.
   ㅇㅈ하는 부분 - 이번 데이터 >> 분포 중요하다고 생각됨

6. 과제 1 상세 — 조업형태 판별

6.1 문제 정의 공지

- 시간대별 MultiLineString 항적의 공간적 특징을 추출하여 어선의 조업형태를 자동 판별합니다.
- 참가자가 직접 추출할 특징의 예로 **이동거리, 방향 변화, 선회 특성, 직선성, 이동범위**가 제시되어 있습니다.
- Train에는 `fishing_code`가 정답으로 있고, Test A에는 없습니다. Test A의 `rfid_id`는 원칙적으로 Train에 없는 신규 선박입니다(선박 ID 암기 방지).

자망이랑 통발 좀 비슷하게 나올듯
둘을 구분하는게 난이도 있을듯
위치에 의한 학습을 하지 않도록 주의할 것
이번 모델은 항적으로 구분해야함

6.2 분류 대상 4종과 예상 항적 특징

공지의 "어선 조업 분류 목록" 그림에는 다음 4종이 있습니다. 아래 그림은 공지 이미지에서 해당 부분만 잘라낸 것입니다.

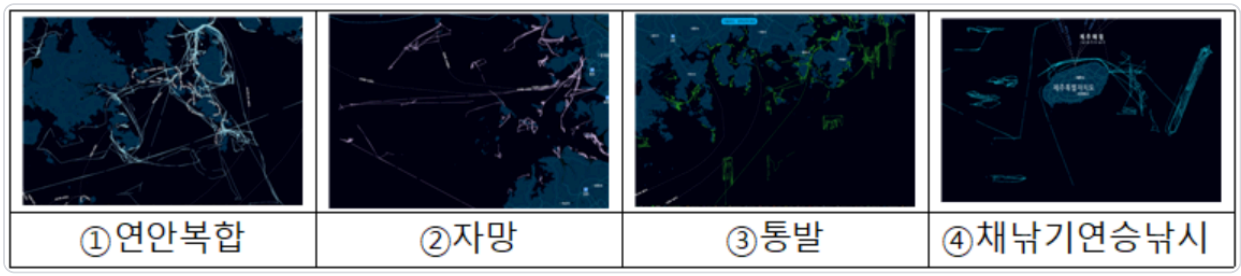


그림 4. 공지에 제시된 조업형태별 항적 예시 (출처: 대회 공지 "목표" 이미지).

조업형태	어업 방식 (일반적 설명)	항적에서 기대되는 특징 추론
자망 (2번)	그물을 물속에 벽처럼 세워 펼쳐 두고, 지나가던 물고기가 그물코에 걸리게 하는 방식. 그물을 내리는 투망과 일정 시간 뒤 걷어 올리는 양망으로 나뉨.	그물을 펼치는 구간의 직선적 저속 이동, 양망 시 매우 느린 이동, 어장까지는 고속 이동. 공지 그림에서도 긴 이동선과 작은 밀집 구간이 섞여 보임.
통발 (3번)	미끼를 넣은 통 모양 덫(통발)을 줄에 여러 개 달아 바닥에 설치하고, 일정 기간 뒤 걷어 올리는 방식.	설치해 둔 어구 위치를 순회하므로 "짧은 이동 → 정지/저속 → 짧은 이동"의 반복. 공지 그림에서는 섬과 연안 주변에 짧은 선이 밀집.
연안복합 (1번)	한 척의 배로 낚시어업, 손꽁치어업, 문어단지어업, 패류껍질어업 등을 하는 연안 소규모 어업(수협뉴스 기사 기준).	연안 가까이에서 다양한 방식이 섞이므로 패턴이 가장 이질적일 것. 다른 클래스와 혼동될 가능성이 가장 큼. 공지 그림에서는 해안선을 따라 얽힌 항적.
채낚기·연승·낚시 (4번)	채낚기: 낚싯줄을 오르내리며 낚는 방식(오징어 등은 야간 집어등 조업이 널리 알려져 있음). 연승(주낙): 긴 줄에 여러 개의 낚싯바늘을 달아 잡는 방식.	채낚기는 야간의 장시간 정지·표류, 연승은 줄을 풀어 놓는 긴 직선 이동과 왕복이 예상됨. 공지 그림은 제주 주변의 길고 평행한 직선 항적.

> **추론 위 표를 대하는 태도**
>
> "어업 방식" 열은 일반적인 어업 설명이고, "기대 특징" 열은 그 방식에서 작성자가 유추한 것입니다. **실제 데이터에서 클래스별 피처 분포를 그려 보고 맞는지 검증**해야 합니다. 특히 1시간 단위·시각 없는 점이라는 데이터 한계 때문에 투망/양망 같은 세부 행동은 잘 드러나지 않을 수도 있습니다. 또한 공지 데이터 설명 표의 "저인망", 목표 문구의 "연승"처럼 표현이 일관되지 않으므로 **Train의 실제 고유 라벨 목록**을 먼저 확인하세요.

6.3 핵심 난점과 대응

배 자체를 알아보는 방법도 필요는 함
그러나 이게 항적을 안보고 유추할 수 있게 되면
그건 좀 벗어나게 되는 이야기라고 생각

(1) 처음 보는 배에 대한 일반화 — 검증 설계가 가장 중요

Train을 행 단위로 무작위 분할하면, 같은 배의 1시 행은 학습에, 2시 행은 검증에 들어갑니다. 모델은 "이 동네, 이 정박 위치, 이 단말 정밀도 = 이 배 = 자망"처럼 **배 자체를 알아보는 방법**을 배우고, 검증 점수는 높게 나오지만 Test A(신규 선박)에서는 크게 떨어집니다. 따라서 `rfid_id`를 그룹으로 하는 **GroupKFold**(같은 배는 한 폴드에만)로 검증해야 합니다 제안 .

데이터가 많으면 폴드를 많이 놔도 좋은데
그러면 모델의 크기가 과하게 커질 수 있어서
고려 좀 해봐야함
(내가 지난번에 5폴드했다가 모델크기 존나
커져서 애먹었음)

(2) 라벨은 선박 단위, 입력은 시간 조각 단위

조업형태는 선박에 고정된 속성일 가능성이 높습니다 추론 (Train에서 같은 rfid_id의 라벨이 항상 같은지 확인 필요). 접근은 두 가지입니다 제안 .

- **집계 후 분류**: 선박(또는 선박-일자)별로 시간대 피처를 평균·분위수·비율로 요약해 한 행으로 만든 뒤 분류.
- **행 분류 후 집계**: 이동이 있는 행만 골라 행 단위로 분류하고, 선박별로 확률을 평균(또는 로그확률 합)해 최종 결정.

굿

어느 쪽이 맞는지는 **Test A가 어떤 단위로 주어지고 어떤 단위로 제출하는지**에 달려 있습니다. 제출 예시의 "파일명(test 데이터1, 2…)" 열을 보면 Test가 여러 파일로 나뉘어 있고 파일당 하나의 예측을 내는 형식일 수 있습니다 추론 . 반드시 확인하세요.

(3) 위치 피처의 양면성

위·경도 자체(어느 해역에 있는가)는 강력한 피처일 수 있습니다(예: 공지 그림상 채낚기연승낚시는 제주 주변). 하지만 Train과 Test의 지역 분포가 다르면 지역을 외운 모델이 틀릴 수 있습니다. **위치 피처를 넣은 모델과 뺀 모델을 GroupKFold로 비교**해 의존도를 확인하는 것이 안전합니다 제안 .

고려해보기

(4) 클래스 불균형

암요 당연히 해야죠

클래스 비율이 크게 다르면 소수 클래스를 거의 예측하지 않는 모델이 나올 수 있습니다. 클래스 가중치, 선박 단위 샘플링, macro-F1 같은 균형 지표로의 모니터링을 고려하세요 제안 .

6.4 피처 설계 목록

그룹	피처 예시	정의·계산 힌트
이동거리 공지	누적거리, 시작-끝 직선거리, 시간대별 이동량	잡음 제거 후 하버사인 합. 파트 사이 점프는 별도 처리(포함/제외 두 버전).
방향 변화 공지	진행 방위각 변화량의 평균·분산·분위수	일정 거리 이상 이동한 구간만으로 방위각 계산(정지 잡음 배제).
선회 특성 공지	90° 이상 급선회 횟수, U턴 횟수, 회전 방향의 일관성	왕복(연승·자망 투망) vs 순회(통발) 구분에 유용할 수 있음 추론 .
직선성 공지	직선거리/누적거리, 구간별 직선성	짧은 창(예: 연속 5점) 단위로 계산해 분포로 요약.
이동범위 공지	경계상자 면적, 회전반경(radius of gyration), 볼록껍질 면적	미터 좌표로 변환 후 계산.
정지·활동 제안	정지 점 비율, 이동 행 비율, 중복점 비율	정박 시간이 긴 업종과 짧은 업종을 구분.
추정 속도 제안	구간 속도의 분위수, 저속(조업 추정)·고속(이동 추정) 비율	균등 간격 가정. 점 수가 적은 행은 신뢰도 낮음(4.5절).
시간 패턴 제안	활동 시간대 분포, 출항·입항 시각, 하루 운항 시간	선박-일자 단위로 행을 이어 계산. 야간 조업 여부 등.
공간 맥락 제안	해안·항구까지 거리, 수심, 해역 구분, 같은 위치 재방문 빈도	외부 데이터 필요 → 사용 허용 여부·라이선스 확인 필요.
데이터 품질 제안	파트 수, 점 수, 좌표 정밀도(0.01′ 격자 여부)	단말 특성이 업종과 상관될 수 있으나 일반화 위험 있음 — 검증으로 판단.

6.5 모델링 단계 제안

1. 파싱	2. 정제	3. 행 피처	4. 집계	5. 기본 모델	6. 개선
WKT → 점 배열, 빈 열·BOM 처리	중복점 제거, 정지 잡음·격자 점프 처리	6.4의 피처를 시간대별로 계산	선박(-일자) 단위로 요약 통계	LightGBM 등 트리 모델 + GroupKFold	확률 보정, 앙상블, 시퀀스·이미지 모델

모델링 단계는 신청서에 작성하려면 어느정도 틀은 잡되
신청서 단계에서 너무 구체적으로 짤 필요는 X
언제든지 수정사항이 생기니까 틀만 잡기

LightGBM, XGBoost등 다양한게 있으니
알고리즘은 좀 생각해볼 것

- **먼저 단순한 기준 모델**(가장 많은 클래스로만 예측 → 피처 몇 개의 트리 모델)을 만들어 점수의 하한선을 확인하세요. 이후 개선이 실제로 의미 있는지 판단할 기준이 됩니다.
- **궤적 이미지 분류**: 공지 예시가 지도 위 궤적 그림이라는 점에서, 선박-일자 궤적을 래스터 이미지로 그려 CNN으로 분류하는 방법도 고려할 수 있습니다. 다만 데이터 양이 적으면 트리 모델보다 나을 보장은 없습니다.
- **확률 출력**이 제출물에 포함되므로, 확률이 실제 정답률과 맞도록 보정(calibration)되어 있는지 확인하는 것이 좋습니다 (평가가 log loss라면 특히 중요 — 지표는 미확인).

7. 과제 2 상세 — 이상항적 탐지

7.1 문제 정의 공지

라벨로 학습하고 없던거로 테스트하는거지 - 당연한 수순

- 정상 및 사고 구간이 포함된 전체 항적을 활용해 **선박별 또는 동일 조업형태별 평상시 항적패턴**을 분석하고, 신규 항적이 기존 패턴과 얼마나 다른지 분석합니다.
- 일부 사고 선박에 대해 사고선박 ID, 사고 발생시각 등 항적과 연계 가능한 사고정보가 제공됩니다. 당연하죠
- 평가는 Test A와 분리된 **Test B**로 합니다. 참가자는 Test B의 **시간대별 이상점수(Anomaly Score)**를 산출하고, 주최측은 별도로 보유한 실제 사고 발생시각을 기준으로 사고 전·후 이상징후를 얼마나 정확하고 조기에 탐지하는지 평가합니다. 당연하죠
- 이상징후 예시: 급격한 이동양상 변화, 급선회, 기존 조업구역 이탈, 동일 선박의 평상시 항적과 현저히 다른 패턴. 네,,,

7.2 왜 어려운가 정식 데이터를 안받았기에 아직은 보류 / 데이터 받으면 얘기 달라질 확률 높은 부분

1. **사고 사례가 매우 적습니다.** 사고 정보가 "일부" 선박에만 있으므로 "사고 vs 정상" 분류기를 학습하기 어렵습니다. 사고 정보는 학습보다는 **검증**에 쓰는 편이 현실적입니다 추론 . 흠 글쎄요 라는 생각이 듦
2. **"정상 데이터"가 깨끗하지 않습니다.** 공지에 따르면 전체 항적에 사고 선박의 사고 전·후 항적도 섞여 있습니다. 정상 패턴을 학습할 때 사고시각 전후 구간을 빼지 않으면, 모델이 이상 패턴까지 "정상"으로 배울 수 있습니다.
3. **이상 ≠ 사고.** 통발 어선의 잦은 방향 전환은 평소 행동이고, 기상 악화로 일찍 귀항하는 것도 "이상"이지만 사고는 아닙니다. 조업형태·선박별 기준선이 없으면 오탐이 많아집니다.
4. **조기 탐지와 오탐의 균형.** 모든 시간대에 높은 점수를 주면 사고는 놓치지 않지만 의미가 없습니다. 평가가 오탐을 어떻게 벌하는지, "조기"를 몇 시간 전까지 인정하는지는 공지에 없습니다 → 확인 필요.
5. **신호가 끊긴 시간대를 어떻게 다루나.** 사고로 단말이 꺼지거나 침수되면 해당 시간대의 행 자체가 없을 수 있습니다 추론 . Test B에 점수를 매길 행이 없는 시간대를 어떻게 처리하는지도 확인 대상입니다.

7.3 이상 지표 후보

이상징후	근거	시간대별로 계산할 지표 예시
급격한 이동양상 변화	공지	직전 시간대 대비 이동량·추정속도·직선성의 변화량
급선회	공지	잡음 제거 후 방위각 변화의 최댓값, 급선회 횟수
기존 조업구역 이탈	공지	선박의 평소 활동 위치 분포(중심·밀도) 대비 현재 위치의 거리 또는 밀도 백분위
평상시와 다른 패턴	공지	같은 선박(또는 같은 조업형태)의 같은 시간대 분포 대비 z-점수·백분위
평소와 다른 시간대 활동	추론	평소 정박하는 시간대에 해상에 있음, 귀항 시각 지연
표류형 이동	추론	해상에서 매우 느리지만 일정한 방향으로 계속 이동(엔진 정지 후 조류에 밀림 가능성)
신호 공백·급변	추론	직전 시간대 대비 점 수 급감, 파트 증가, 행 누락 직전·직후

7.4 접근 단계 제안

단계 1. 규칙 기반 점수 (해석이 쉬움, 가장 먼저) 당연히 해야죠

7.3의 지표를 시간대마다 계산 → 각 지표를 학습 데이터 분포에서의 **백분위(0~1)**로 바꿈 → 가중 평균하거나 최댓값을 취해 이상점수로 사용. 0~1 범위 요구를 자연스럽게 만족합니다.

단계 2. 기준선(Baseline) 비교 난 이전에 베이스라인 모델을 하나 만들고 점점 조건을 추가하면서 M1, M2, M3 .... 이렇게 만들고 비교했었음

- **선박별 기준선**: Test B 선박의 과거 항적이 Train에 있다면, 그 선박의 평소 분포와 비교합니다("동일 선박의 평상시 항적").
- **조업형태별 기준선**: 선박 이력이 없으면 과제 1 모델로 조업형태를 추정한 뒤, 같은 형태의 평상시 분포와 비교합니다.
- Test B 선박이 Train에 포함되는지는 공지에 없으므로 확인 필요합니다(어떤 기준선을 쓸 수 있는지가 이것으로 결정됨).

단계 3. 학습형 이상탐지 Isolation이랑 오토인코더는 너무 단골이라 창의성 점수는 좀 떨어질듯

- **Isolation Forest / One-Class 모델**: 정상 시간대 피처로 학습 → 고립되기 쉬운 시간대일수록 높은 점수.
- **오토인코더 재구성 오차**: 정상 항적 패턴을 압축·복원하도록 학습 → 복원이 잘 안 되는 시간대가 이상.
- **다음 시간대 예측 오차**: 과거 몇 시간의 항적으로 다음 시간대를 예측 → 예측과 실제의 차이가 크면 이상.

단계 4. 후처리와 검증

- **시간 평활**: 한 시간대의 튀는 값보다 연속된 이상이 의미 있으므로 이동평균·지수평활을 적용합니다. 단, 과하면 탐지가 늦어집니다(조기 탐지 평가와 상충).
- **사고 선박으로 검증**: 제공된 사고시각 기준으로 "사고 몇 시간 전부터 점수가 올라가는가", "같은 선박의 평상시 날에는 점수가 낮은가"를 그려 보며 지표 가중치를 조정합니다. 굿

> **가상 예시 — 이상점수가 높아지는 시나리오 (실제 데이터 아님)**
>
> 통발 어선 B는 평소 05~11시에 항구에서 5 km 이내 섬 주변을 순회하고 12시 전에 귀항합니다. 어느 날 B가 ① 03시에 평소보다 일찍 출항하고(시간대 이탈), ② 08시에 연안 25 km 바깥에 있으며(구역 이탈), ③ 09~11시에는 거의 정지한 채 한 방향으로 아주 느리게 밀려가고(표류형 이동), ④ 12시 이후 행이 사라졌다면(신호 공백) — 각 지표가 동시에 높아지므로 08시 무렵부터 점수가 올라가야 "조기 탐지"가 됩니다. 반대로 같은 움직임이 원래 외해에서 조업하는 연승 어선에게는 덜 이상할 수 있으므로 기준선이 중요합니다.

8. 제출물 정리 여기서부터 가볍게 훑어보기

8.1 결과 제출 양식 공지

파일명	예측 조업형태	예측 조업형태 확률(0~1)	이상항적 점수(0~1)
test 데이터1	자망	0.82333	0.11122
test 데이터2	통발	0.912133	0.88552

열	해석과 불확실성
파일명	예측 단위가 "파일"임을 시사합니다. 파일이 선박 하나인지, 항차 하나인지, 시간대 하나인지는 불명확합니다 추론 .
예측 조업형태	클래스 이름 문자열(한글)로 쓰는 형식으로 보입니다. 철자를 Train 라벨과 정확히 맞춰야 합니다(예: "채낚기연승낚시").
예측 조업형태 확률	4개 클래스 전체 확률이 아니라 **예측한 클래스의 확률 하나**를 쓰는 형식으로 보입니다 추론 .

열	해석과 불확실성
이상항적 점수	과제 2는 “시간대별” 점수를 요구하는데 예시는 파일당 한 값입니다. 또 Test A·B가 분리된다고 했는데 한 표에 두 과제 결과가 함께 있습니다. **최종 양식은 주최측 확인이 필요**합니다.

8.2 서류·발표 평가 대비 제안

- **제안서(신청서 양식)**: 데이터 활용 방안·분석 방법론, 추진일정, 예상 결과물을 구체적인 숫자와 그림으로 채웁니다. 이 문서의 3.3절 파이프라인, 6.4절 피처표, 7.4절 단계가 뼈대가 될 수 있습니다.
- **설명 가능성**: 피처 중요도, 클래스별 대표 궤적, 혼동행렬(어떤 형태끼리 헷갈리는가), 사고 선박의 시간대별 점수 그래프를 준비합니다.
- **실무 활용 시나리오**: “관제 화면에서 이상점수 상위 선박을 우선 확인” 같은 사용 장면과 오탐률을 함께 제시하면 설득력이 올라갈 것입니다.
- **재현 가능한 코드**: 수상 시 코드 공개에 동의해야 하므로, 데이터 경로만 바꾸면 처음부터 결과가 재현되도록 정리합니다.

9. 주최측에 확인해야 할 질문 우리가 본격적인 데이터를 받고, 같이 대가리 굴리면 해결되는 것들이 많음, 여기도 대충 보셈

공지만으로는 결정할 수 없고, 답에 따라 설계가 크게 바뀌는 항목들입니다. 운영사무국(aidatacon@gmail.com) 또는 플랫폼 Q&A로 문의하는 것을 권합니다.

#	질문	왜 중요한가
1	과제 1의 평가지표는? (정확도, macro-F1, log loss 등)	확률 보정·클래스 가중치 전략이 달라짐
2	Test A·B의 제공 단위와 제출 단위는? 제출 양식의 “파일명”은 무엇을 뜻하나?	행 단위 vs 선박 단위 모델 선택이 결정됨
3	과제 2의 평가 방식: 사고 전 몇 시간까지 “조기 탐지”로 인정하나? 오탐은 어떻게 반영되나?	평활 강도, 점수 분포 설계가 달라짐
4	Test B의 선박이 Train에 포함되나?	선박별 기준선 사용 가능 여부
5	조업형태 클래스 목록은 4종(연안복합/자망/통발/채낚기연승낚시)으로 확정인가? “저인망”은 포함되나?	모델 출력 공간 확정
6	사고정보는 어떤 형식(파일, 컬럼)으로, 몇 건 제공되나?	과제 2 검증 설계
7	외부 데이터(해안선, 항구 위치, 수심, 기상·해상 정보)와 사전학습 모델 사용이 허용되나?	공간 맥락 피처 사용 가능 여부 (규정 2: 저작권 해결 필요)
8	데이터의 기간과 연도(샘플은 2025년, 공지 예시는 2026년)는?	계절 피처, Train/Test 기간 분할 설계
9	MultiLineString의 파트는 어떤 기준으로 나뉘나? 점의 기록 간격은 일정한가?	속도 추정의 신뢰도
10	제출 횟수 제한·리더보드 유무, 참가신청서(제안서) 제출 기한은?	일정 계획

10. 남은 25일 진행 로드맵 제안 ***여기서부터는 대충 보셈

문제 해결 마감(11.06 금)까지 약 3.5주입니다. 과제 2는 과제 1의 피처를 재사용하므로 과제 1을 먼저 빠르게 세우는 순서를 권합니다. 팀 규모나 제출 기한이 다르면 조정하세요.

기간	목표	할 일
1주차 10.12 ~ 10.18	데이터 파악	09.28 업데이트 버전 확보 · 9장 질문 발송 · WKT 파서와 정제 함수 작성 · EDA(선박 수, 선박당 행 수, 클래스 분포, 정지 행 비율, 파트·점 수 분포, 좌표 정밀도 분포) · 같은 선박의 라벨이 항상 같은지 확인

기간	목표	할 일
2주차 10.19 ~ 10.25	과제 1 기준 모델	6.4 피처 구현 · 선박(-일자) 집계 · GroupKFold 기반 LightGBM · 위치 피처 유무 비교 · 혼동행렬 분석
3주차 10.26 ~ 11.01	과제 2 점수 체계	사고 전후 구간 제외한 정상 분포 구축 · 규칙 기반 점수 → 기준선 비교 → (여유 시) Isolation Forest · 사고 선박으로 시간대별 점수 그래프 검증
4주차 11.02 ~ 11.06	마무리·제출	튜닝·앙상블 · 제출 파일 형식 점검(클래스 철자, 0~1 범위) · 보고서/제안서 작성 · 코드 정리
11.09 ~ 11.25	평가 대응	서류 평가 기간 이메일 확인 · 후보 선정 시 발표 자료 준비(그림·사례 중심)

가장 먼저 해야 할 세 가지

1. 최신(09.28) 데이터 확보와 9장 질문 1·2·3번 문의
2. Train에서 **선박 단위**로 클래스 분포와 "정지 행 비율"을 확인 → 행 단위로 풀지, 선박 단위로 풀지 결정
3. GroupKFold 검증 틀을 먼저 만들어 두고, 그 위에서만 성능을 비교

부록 A. 용어 정리

용어	뜻
V-Pass (선박패스)	어선 위치를 자동 발신하는 장치. 출입항 자동 신고, SOS 경보 기능 포함
WKT	Well-Known Text. 공간 도형을 문자열로 표현하는 표준 형식
하버사인(Haversine)	지구를 구로 보고 두 경위도 좌표 사이의 대원 거리를 구하는 공식
직선성(straightness)	시작-끝 직선거리 ÷ 실제 이동거리. 1이면 일직선
회전반경(radius of gyration)	점들이 중심에서 평균적으로 얼마나 퍼져 있는지 나타내는 값
GroupKFold	같은 그룹(여기서는 같은 선박)이 학습과 검증에 동시에 들어가지 않도록 나누는 교차검증
이상점수(Anomaly Score)	평상시 패턴에서 벗어난 정도를 수치로 나타낸 값. 이 대회에서는 0~1
투망·양망 / 투승·양승	그물을 내림·걷어 올림 / 낚시줄(연승)을 내림·걷어 올림
노트(knot)	선박 속도 단위. 1노트 = 시속 1.852 km

부록 B. 출처

1. 대회 포스터 "2026 DATA·AI 분석 경진대회" (사용자 제공 이미지)
2. 대회 공지 이미지: 문제 개요, 목표, 데이터 설명·변경사항 안내 (사용자 제공 이미지 3장)
3. 2026_참가신청서.hwp — 한국과학기술정보연구원 (사용자 제공)
4. 어선 과제 샘플데이터.csv — 10행 (사용자 제공)
5. Journal of Marine Science and Engineering (2023), 11(5), 1023. "Investigating the Reliability of the Location Transmitted by V-Pass Terminals: Prompt Rescue of Fishing Vessels." https://www.mdpi.com/2077-1312/11/5/1023
6. 수협뉴스, "긴 낚싯줄에 여러 개 낚싯바늘 사용 '주낙어업' – 업in수산." https://www.suhyupnews.co.kr/news/articleView.html?idxno=29981
7. 한국민족문화대백과사전, "연안어업." https://encykorea.aks.ac.kr/Article/E0068273
8. 한재림·김태훈·최은영·최현우 (2021). 선박패스(V-Pass) 자료를 활용한 어업활동 지도 제작 연구 – 남해동부해역을 중심으로. 한국지리정보학회지 24(1), 112–125. https://www.koreascience.or.kr/article/JAKO202111841186028.page
9. 해안선: GSHHS 데이터 (matplotlib basemap 패키지 내장)

※ 자망·통발·채낚기에 대한 설명은 일반적인 어업 용어 설명이며, 위 출처에서 직접 인용한 것은 연안복합어업의 구성과 연승(주낙)의 정의(6번), V-Pass 기능·수신 특성(5번), 업종·계절별 어업활동 분포 차이(8번)입니다.

부록 C. 시작용 코드 예시 제안

아래 코드는 샘플 CSV 구조를 기준으로 한 출발점입니다. 실제 Train 파일명·컬럼에 맞게 바꿔 쓰세요. 필요 패키지: `pandas`, `numpy`, `shapely`, `scikit-learn`.

주의 — ① `np.vstack(parts)` 는 파트를 이어 붙이므로 파트 사이의 "점프"도 거리에 포함됩니다. 포함/제외 두 버전을 실험해 보세요. ② `lon_mean`, `lat_mean` 같은 위치 피처는 6.3(3)의 이유로 넣은 버전과 뺀 버전을 비교하세요. ③ 임계값(10 m, 200 m)은 예시이며 데이터로 정해야 합니다.

```
# 1) 읽기: BOM 처리 + 이름 없는 빈 열 제거
import numpy as np, pandas as pd
from shapely import wkt

df = pd.read_csv("train.csv", encoding="utf-8-sig")
df = df.loc[:, ~df.columns.str.startswith("Unnamed")]

# 2) 레코드(1시간 항적) 하나에서 피처 계산
R = 6_371_000  # 지구 반지름(m)

def haversine(lon1, lat1, lon2, lat2):
    lon1, lat1, lon2, lat2 = map(np.radians, (lon1, lat1, lon2, lat2))
    a = np.sin((lat2-lat1)/2)**2 + np.cos(lat1)*np.cos(lat2)*np.sin((lon2-lon1)/2)**2
    return 2 * R * np.arcsin(np.sqrt(a))

def record_features(geom_text, stop_m=10.0):
    g = wkt.loads(geom_text)
    parts = [np.asarray(line.coords) for line in g.geoms]
    pts = np.vstack(parts)                      # (N, 2) = [경도, 위도]
    lon, lat = pts[:, 0], pts[:, 1]
    step = haversine(lon[:-1], lat[:-1], lon[1:], lat[1:])   # 인접 점 간 거리(m)
    moving = step[step >= stop_m]               # 정지 잡음 제거(임계값은 실험으로 결정)
    total = moving.sum()
    disp = haversine(lon[0], lat[0], lon[-1], lat[-1])
    return {
        "n_parts": len(parts),
        "n_pts": len(pts),
        "uniq_ratio": len(np.unique(pts, axis=0)) / len(pts),
        "total_m": total,
        "disp_m": disp,
        "straightness": min(disp / total, 1.0) if total > 0 else 0.0,
        "stop_ratio": (step < stop_m).mean() if len(step) else 1.0,
        "max_step_m": step.max() if len(step) else 0.0,
        "lon_mean": lon.mean(), "lat_mean": lat.mean(),
    }

feat = pd.DataFrame([record_features(s) for s in df["geom"]])
data = pd.concat([df[["part_dt", "rfid_id", "rfid_time", "fishing_code"]], feat], axis=1)

# 3) 선박 단위 집계 (예: 평균·최댓값·이동 행 비율)
data["is_moving"] = data["total_m"] > 200
vessel = data.groupby("rfid_id").agg(
    label=("fishing_code", "first"),
    n_rows=("rfid_time", "size"),
    moving_ratio=("is_moving", "mean"),
    total_m_mean=("total_m", "mean"),
    total_m_p90=("total_m", lambda s: s.quantile(0.9)),
    straight_mean=("straightness", "mean"),
)

# 4) 선박 단위로 나누는 교차검증 (행 단위로 학습할 때 특히 필수)
from sklearn.model_selection import GroupKFold
X = data.drop(columns=["fishing_code", "rfid_id", "part_dt"])
y = data["fishing_code"]
for tr_idx, va_idx in GroupKFold(n_splits=5).split(X, y, groups=data["rfid_id"]):
    pass  # 여기서 모델 학습/검증 — 같은 선박이 양쪽에 들어가지 않음
```