IT종합설계프로젝트

프로젝트 제안서

MLP 기반 어선 조업형태 분류 및 이상항적 분석



제출일	2026.10.19	**전공**	전자전기공학부
과목	IT종합설계프로젝트	**학번**	C215192
담당교수	고경준 교수님	**이름**	최승빈

목차

- 프로젝트 개요
  1) 문제 배경과 필요성
  2) 데이터 특성 파악 및 전처리 방향성
  3) 프로젝트 목표

- 프로젝트 내용
  1) 모델 설계 구상과 이유
  2) 비교 실험 및 검증 계획
  3) 조건부 확장 방안

- 요약 및 향후 추진 일정
  1) 요약
  2) 향후 추진 계획

━프로젝트 개요

1) 문제 배경과 필요성

넓은 관할 해역의 수많은 어선들을 인력에 의한 모니터링 만으로 사고나 불법조업 등의 문제를 신속하게 판별하는 데에는 어려움이 있다. 해당 문제에 대해 분석하기 위해, 먼저 현재 선박의 체계에 대해 알아보고자 하였다. 선박의 위치에 관한 정보는 어선법에 따라 어선 위치 발신장치인 선박패스(V-Pass)에 의해 수집될 수 있다. 어선의 위치를 자동으로 발신하는 V-Pass는 어선에 설치되어 해양경찰 측 수신국으로 위치를 전송하도록 기능한다. 단말의 SOS 버튼이나 안테나 분리 시 경보가 전송되기도 하며, 자동 출입항 신고 시스템과도 연동되어 있어서 복잡한 절차 없이도 출항 및 입항 신고가 가능한 체계이다. 해당 기능은 30초 간격으로 위치를 저장하고, 10분 이내 간격으로 발신하게 되어 있는데, 최근 해상 실험에서는 4시간 동안의 기대 패킷 480개 중 269개만 수신되는 등 누락 사례가 보고되었다.

V-Pass로 얻게 되는 항적 데이터는 이와 같은 누락으로 인해 점으로 저장되는 위치 정보의 간격이 균일하지 않고, 비어 있는 경우가 발생할 수 있다. 속도 추정의 오차인지, 어선 1척이 1시간 동안 움직인 경로를 담는 MultiLineString이 여러 조각으로 나뉘는 현상인지, 신호가 단순히 끊긴 것인지, 수신의 누락인 것인지 구분하기 어려운 문제를 마주한 것이다.

따라서 위와 같은 상황을 해결하기 위해 조업방식에 따른 어선들의 항적 패턴을 분석 및 학습하고, 시간대별로 비교하여 평상시와 다른 이동 양상을 보이는 이상징후를 탐지하는 모델을 설계하고자 한다.

2) 데이터 특성 파악 및 전처리 방향성

데이터는 CSV파일을 통해 확인이 가능하며, 데이터 한 행이 의미하는 바는 특정 선박의 특정 일자 및 시간대 이동항적이다. 5개의 칼럼으로 구성되며, ‘part_dt’, ‘rfid_id’, ‘rfid_time’, ‘geom’, ‘fishing_code’로 나뉜다. ‘part_dt’는 일자, ‘rfid_id’는 선박의 식별 번호, ‘rfid_time’은 시간대, ‘fishing_code’는 해당 선박이 무슨 어업에 해당하는지 알 수 있게 해주는 정보이다. 어업의 종류에 대한 정보는 이어지는 그림을 통해 확인할 수 있다. ‘geom’은 CSV파일에서 가장 중요하게 다뤄지는 정보인데, MultiLineString으로 해당 선박이 1시간 동안 움직인 경로를 경도와 위도의 순서쌍들의 나열로 알 수 있다. 좌표별 시각의 유무에 따라 정확한 순간 속도와 체류시간을 산출할지 결정할 것이다.

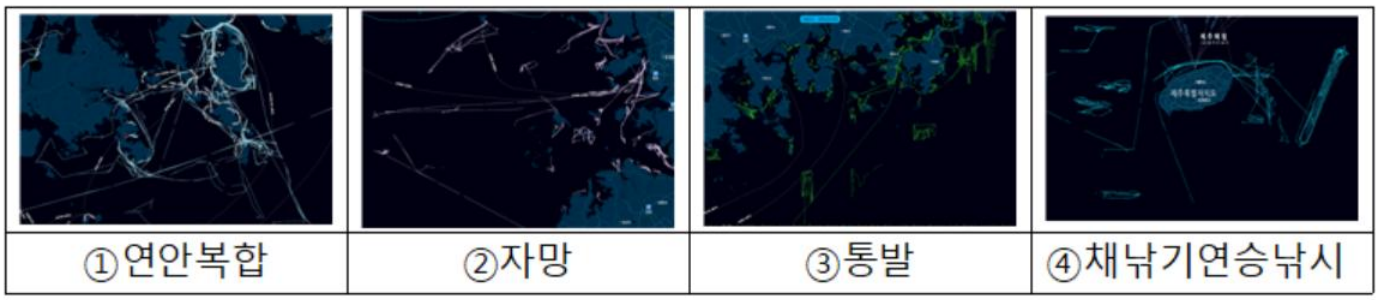


그림 1 어선의 조업 분류 목록

데이터를 분석해 보았을 때, 주의할 점들에 대해 먼저 생각해보았다. 우선, 시간 정보는 '조업은 계절의 영향을 크게 받는다'는 점과 '어선 활동은 특정 시간대에 이루어질 확률이 높다'는 점으로 미루어 보면 해당 선박의 조업에 대한 힌트로 제공될 가능성이 있다. 이번 프로젝트를 통해 설계하려는 모델은 언제나 이동 항적 데이터를 바탕으로 판단해야 하기 때문에, 활용의 여지는 있으나 이를 과하게 학습하지 않도록 주의해야 한다고 판단했다. 선박의 식별값 자체를 feature로 활용하면 안 된다는 점을 인지하고 있다. Test 데이터는 신규 선박에 해당하기 때문이다.

이번 프로젝트에서는 핵심이 되는 'geom' 좌표의 값(경도, 위도)에 해당하는 정보를 활용하여 'fishing_code'를 잘 분류하는 것에 초점을 두고 있다. 경도와 위도는 문자열 WKT로 제공된다. WKT는 점, 선, 면과 같은 공간 도형을 사람이 읽을 수 있도록 문자열로 적는 표준 형식인데, MultiLineString이 해당 형식으로 작성되었기에 숫자 좌표로 바꾸는 과정인 '파싱'과 같은 방법을 적용할 예정이다. 선의 구조를 보존하기 위해 분리된 구간을 임의로 잇지 않고, 데이터 파일에 명시되지 않은 정보에 대해서도 판단해야 한다. 연결 구간별 이동거리, 굴곡, 범위 등 형상 특징과, 좌표의 수와 반복되는 비율, 구간의 수, 결측 등의 관측 정보가 이에 해당한다.

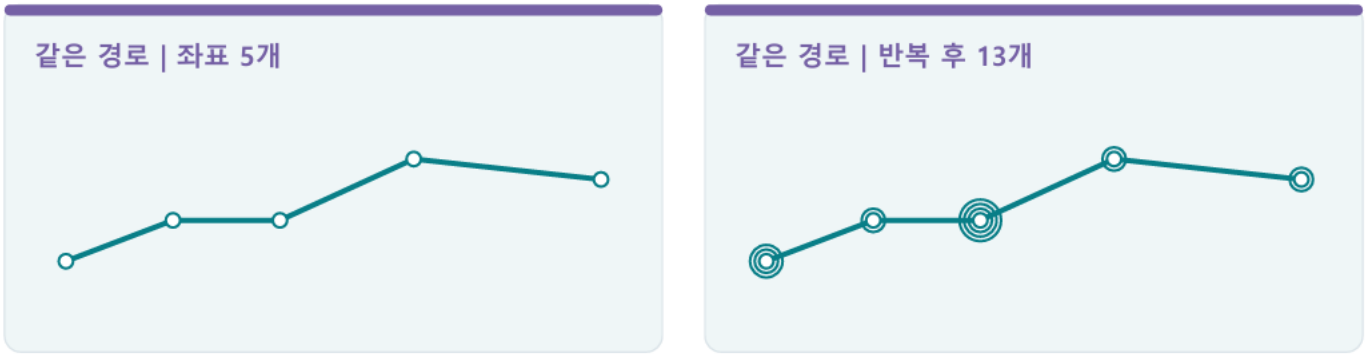


그림 2 형상 특징과 관측 정보

이동 경로의 형상과 관측 상태를 별도의 특징으로 구성할 계획이다. 동일 경로에 반복된 좌표만 추가하는 비교 실험을 통해 조업 예측의 불필요한 변동을 줄이면서도 관측의 변화는 별도로 확인할 수 있는지 검증해보고자 한다. 정리하자면, 형상 계산용으로 연속적인 중복은 압

축하되, 반복 횟수를 남겨서 그 기록을 보존한다. 동시에 좌표계와 경도, 위도의 순서를 확인함으로써 시간과 공간의 의미 역시 보존한다.

앞서 확인했던 문제 배경에서 알 수 있듯이, 경도와 위도가 나열된 좌표 값에 공백의 구간이 있기에 이 점에 유의해야 한다. 학습 데이터에서는 'fishing_code'를 정답 label로 활용하겠지만, Test 데이터에서는 항적 데이터만 활용하기에 이를 잘 분류할 수 있도록 모델을 설계하고자 한다.

3) 프로젝트 목표

본 프로젝트를 통해 어선 항적에 AI 알고리즘을 적용한 모델을 설계하여 조업형태를 분류하고, 확인이 필요한 항적 패턴을 제시하는 것이 주된 목표이다. 최근 MLP의 구조와 학습법에 대한 연구 자료를 확인할 수 있었는데, 이번 데이터에 적합하다고 판단하여 사용하기로 결정하였다. 기존 방법의 적용 및 개선 실험, 즉 베이스라인 비교 실험을 통해 설계한 모델의 성능을 판단할 것이다. MLP 구조 중에서도 최근 연구된 TabM, RealMLP 신경망을 실제로 학습시키고 평가하는 방향으로 진행하고자 한다.

이번 프로젝트 계획의 큰 틀은 필수적인 요소와 확장 요소로 나뉜다. 필수적인 요소는 공통된 특징을 추출하여 MLP 비교를 진행하고, 이상점수 검증을 한 뒤 조업을 분류하고 이상항적을 분석하는 것이다. 그 후, Transformer와 TabPack 신경망, 확률 보정 등등의 과정을 하나씩 추가하여 결과에서 발생하는 변화를 확인하고자 한다.

필수적인 요소 중 세부적인 목표 사항은 두 가지이다. 첫 번째는 조업형태 분류이다. 학습 데이터로 학습시킨 모델을 이용하여 처음 보는 선박의 항적을 바탕으로 조업 종류와 그 종류의 분류 확률에 대해서 알 수 있어야 한다. 선박의 ID를 외우지 않고 항적 특징을 학습하여 학습 데이터에 존재하지 않던 새로운 선박에 적용해보는 과정이 필요하다. 두 번째는 이상항적 분석이다. 시간대별 항적과 이용 가능한 데이터를 사용하여 평소와 다른 정도를 나타내는 시간대별 이상점수를 0~1까지 표현할 것이다. 이를 사고 정보와 연계하여, 탐지한 이상징후와 사고 발생의 관련성을 검증한다.

━프로젝트 내용

1) 모델 설계 구상과 이유

이번 프로젝트에서 조업 분류에는 TabM 혹은 RealMLP 신경망을 적용하여 두 후보를 비교하며 적용 여부를 판단할 예정이다. TabM 신경망을 적용할 때는 계산 규칙의 대부분을 공유하는 여러 MLP의 예측이 원활하게 모아지는지 확인하고, 여러 예측을 모으는 효과와 비용을 확인하는 데에 초점을 맞출 것이다. 반면, RealMLP 신경망을 적용할 때는 입력 변환, 초기값, 암기 제어 등이 개선되었기에 안정성 확인에 초점을 맞추어 진행할 것이다.

또한 해당 섹션에서 LightGBM 결정 트리 알고리즘을 함께 결합하여 비교하고자 한다. MLP와 LightGBM의 같은 조업 클래스 확률을 평균하여 클래스 순서와 혼합 비중을 고정하는 시도를 진행할 것이다. 아래 이미지는 위 내용을 도식으로 나타낸 것이다.



그림 3 모델 설계 방향

왜 TabM과 RealMLP 신경망이 해당 프로젝트에 적합하다고 판단했는지 그 이유는 다음과 같다. 우선, WKT 좌표를 입력으로 사용하는 이번 프로젝트의 데이터에 적합하다. 형상 특징과 관측 상태가 숫자 feature로 존재하고, MLP는 숫자 특징을 여러 layer에서 조합해 판단하는 신경망이라는 점을 고려하였다. 거리와 굴곡, 범위를 추출하면 고정된 열의 숫자표가 되는데 두 모델 모두 이 표를 학습하기에 적합하다. 두 번째, 비교가 가능하다는 점이다. 같은 특징과 선박 분할에 있어서 신경망 단독 비교, LightGBM을 작은 규모로 적용해서 단독 비교, 설계한 모델 간의 혼합 비교 등 비교하며 검증하기에 적합하다. MLP 외에도 다른 결정 트리,

Attention 기반 모델 등등 활용이 가능하지만, 현재 입력 데이터에 초점을 맞추었다.

TabM의 핵심은 새로운 MLP 이론이 아닌 여러 MLP 예측의 효율성, 즉 구조 개선이다. 여러 신경망의 판단을 모으면 도움이 될 수 있으나, 완전한 모델을 여러 개 보관하거나 학습시키면 비용이 커지는 문제가 발생한다. 계산 규칙을 대부분 공유하여 각 예측이 작은 개별적인 조정값을 갖도록 하여 완전한 신경망을 복제하는 부담을 줄였다. 각 예측의 오류를 학습하기도 한다. 학습 과정부터 여러 예측을 함께 다루고 결합 성능을 검증하며, 분류 추론 단계에서는 클래스 확률을 평균하는 구조이다.

RealMLP의 핵심은 입력 전처리, 신경망의 초기화, 과적합을 방지하는 방법과 학습 설정을 개선하여 표 형태의 데이터에 적합하다는 것이다. 스케일 조정에 유리하고, 숫자를 학습하기 쉬운 표현으로 바꾸며 특징의 영향 크기를 조절하기도 한다. 초기화, Regularization, 과도한 암기를 방지하는 설정도 개선된 신경망이다.

학습 자료의 중앙값이나 분포 등으로 일반적인 이동 항적의 비교 기준을 만든다. 이는 학습 데이터를 통한 여러 선박들의 항적을 바탕으로 만들어지는 것이며, 새 항적의 이동거리, 굴곡, 범위가 해당 기준에서 얼마나 벗어나는지를 확인하여 이상점수를 매기는 방향으로 진행된다. 단, 사고와 관련된 구간이 확인되면 따로 분리한다.

첫 모델 설계에서는 MLP의 layer 수나 결정 트리의 깊이와 개수를 제한하는 등 작은 크기의 모델로 시작할 계획이고, 추가적으로 모델의 검증을 바탕으로 한 이득과 비용을 확인한 뒤 모델의 규모와 방향성에 대한 재검토를 진행한다. 추가적인 이상탐지기는 추후 비교하며 설계를 진행한다.

2) 비교 실험 및 검증 계획

조업 분류 데이터는 선박 ID를 기준으로 학습, 검증, 최종 평가로 분리할 것이다. 전처리 기준은 학습 데이터를 통해 결정되며, 모델의 선택 여부와 혼합되는 비중은 검증 단계에서 결정될 것이다. 최종 평가 데이터는 확정된 모델의 성능을 확인하는 용도로 사용될 것이다.

조업 분류에 관한 비교 및 검증은 LightGBM, TabM, RealMLP 단일 및 혼합 비교를 통해 진행된다. 조업형태를 분류할 때 내부 비교 지표로 조업 종류별 정밀도와 재현율을 확인하고, 이후 각 조업 종류의 F1을 동일한 비중으로 평가하는 Macro-F1을 사용한다.

사고 관련 이상징후 탐지는 같은 사건이 학습 및 평가에 중복되지 않도록 시간 순서를 지키며 평가 가능한 사건의 수와 사건별 탐지율, 놓친 사건의 수, 경보 발생량 등을 함께 확인한다.

WKT 데이터 처리부터 모든 모델의 예측까지 소요되는 시간과 메모리 사용량 등을 확인하며 확률의 품질 정도와 실패 및 결측 사례 등의 정보 역시 확인하여 최적화 과정도 진행하고자 한다.



그림 4 조기탐지 선행시간 산정 예시

조기탐지는 사고 관련 이상징후를 발견한 뒤, 상황을 확인하고 대응을 판단할 시간을 확보할 수 있다는 점에서 중요한 요소이다. 본 프로젝트의 모델을 사용했을 때, 항적을 추가로 확인하고 필요한 조치를 판단할 시간을 얻을 수 있으며, 이상징후를 얼마나 정확하고 일찍 탐지하는지는 프로젝트의 근본적인 목표와 연결된다.

모델 간 조기탐지 성능을 같은 기준으로 비교 검증하는 시도도 진행한다. 모델별로 항적 데이터 수집 시작 시간 계산과 실제 경보 가능 시간 계산이 다르면 올바른 비교가 불가능하다. 따라서 모든 모델에 적용할 시간 계산 기준을 맞춰야 한다. 위 그림은 사고를 얼마나 일찍 탐지했는지 계산하는 기준을 설명하는 예시이다. 09시부터 10시까지 한 시간 동안의 항적을 모으고, 10시 5분경 자료 처리와 이상점수 계산이 끝나 경보를 낼 수 있는 상황이며, 11시 30분에 사고가 발생했다고 가정한 것이다. 10시 5분경에 이상징후를 발견하여 경보를 냈다면, 사고보다 85분 앞서 알린 것이기에 9시에 낸 것처럼 계산하면 조기탐지 성능이 부풀려진 것에 해당한다. 따라서 이번 프로젝트에서의 사고 이전의 이상징후를 일찍 발견할 가능성을 검증하는 단계에서 사고 시각과 데이터 가용 시각을 확인하여, 당시 사용할 수 있었던 정보만으로 평가하도록 설계해야 한다.

3) 조건부 확장 방안

이번 프로젝트에서 인코더, 디코더, 트랜스포머의 활용 가능성에 대해서도 추가적으로 살펴보고자 한다. 인코더와 디코더는 각각 입력을 유용한 특징으로 요약하고, 요약된 내용을 입력으로 복원하는 기능을 하는데, 다음 이미지와 같은 구조로 활용될 수 있다고 생각한다. 또한, 트랜스포머는 특징 및 시점 사이의 관계를 학습하는 구조로, 인코더를 구성할 때 사용할 수 있다고 생각한다.

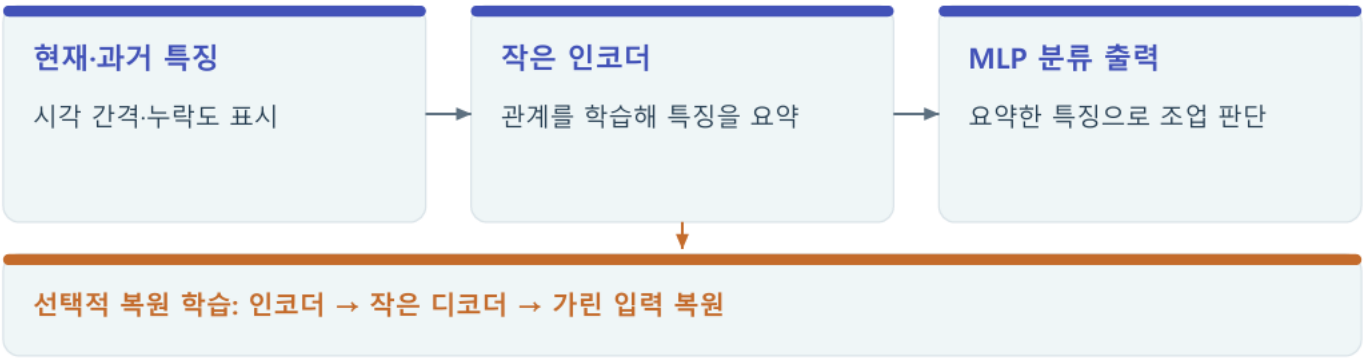


그림 5 인코더와 디코더 활용

연속적인 시간대가 확보된다면, 과거와 현재의 특징점을 작은 트랜스포머 인코더에 넣어 MLP로 분류하는 방향성에 대해 생각해보았다. 시간 정보가 부족하다면 현재 시간대의 표현 특징만 사용하는 Attention 모델도 비교가 가능해진다.

학습 입력의 일부를 가리고 복원하는 보조 학습 장치를 사용해보는 구상을 제시한다. 분류만 시행할 때 디코더는 제거할 수 있지만 복원 오차로 이상점수를 산출할 때에는 유지된다. 추가로, 복원 오차가 발생했다는 점이 사고를 의미하는 것인지도 검증 가능하다.

현재 사용하려고 계획한 TabM, RealMLP 신경망의 후속 연구에 대해서도 살펴보았다. TabPack 신경망은 TabM의 후속 연구 결과인데, 다른 설정의 MLP들을 한 번에 학습 및 선택하여 설정 탐색 비용을 줄인다. 충분한 학습 및 검증이 완료되면 적용 가능성을 검토한다. 이외에도 예측의 확신 정도를 조정하는 추가 기능을 RealMLP에 적용하여 F1 지표와 함께 확률 품질을 확인하는 방법에 대해서도 추가적인 검토를 진행하고자 한다.

━요약 및 향후 추진 일정

1) 요약

본 프로젝트는 MLP 기반 딥러닝을 어선 항적 분석에 적용하는 AI 응용 모델 설계 프로젝트이다. 시간대별 항적의 이동 형상과 관측 상태를 구분하고, 새로운 선박의 조업형태를 분류하여 평소와 다른 항적을 찾는 경량 분석 모델을 설계하는 데에 초점을 맞췄다. 예측 성능뿐만 아니라 사고 관련 이상징후의 탐지 가능성도 함께 검증하고자 한다.

항적의 이동 형상과 관측 상태를 구분하여 구성한 특징을 바탕으로 TabM과 RealMLP 신경망을 이용하여 설계한 모델을 동일한 조건에서 비교한다. LightGBM 결정 트리도 함께 결합하여 모델의 성능을 확인하며, 시간대별 이상점수를 출력하여 비교 및 검증하는 단계를 진행한다.

학습에 사용하지 않았던 새로운 어선들의 항적 정보가 담긴 데이터를 활용하여 신규 어선들에 대한 분류 성능과 사고 관련 이상징후의 조기탐지 가능성도 평가한다. 실제 데이터를 기준으로 탐지 선행시간, 경보 시간, 비용을 정리하고, 예측 결과 파일과 재현 가능한 코드, 분석 결과를 최종 결과물로 제시할 예정이다.

2) 향후 추진 계획

단계	수행 내용
데이터 구조 파악	샘플 데이터의 항적 형식과 결측 및 중복 여부를 확인하고, 이동 경로와 관측 상태를 구분하여 사용할 특징을 정리한다.
학습 및 평가 준비	데이터의 구성과 사고 정보, 제출 형식을 확인한다. 어선, 사고 사례, 시간 순서를 고려하여 학습 및 평가 자료를 구분한다.
기본 모델 구현과 비교	모델 별 분류 성능 비교 후, 관측 상태의 특징과 모델 결합 효과를 확인한다. 학습 항적을 이용해 이상점수 산출 기준도 마련한다.
성능 검증과 보완	사고 관련 이상징후 탐지 시점과 경보 발생량을 확인한다. 추가적인 개선 방향을 조건부 확장 방안을 통해 검토한다.
결과 정리 및 발표	결과 재현 여부를 확인하고, 모델의 성능과 한계점을 명시한다. 예측 결과와 재현 코드, 분석 결과를 제출한다.