CPU로 시작하는 분석 설계

V1의 상세 설명과 V2의 기술적 보완을 주제별로 합쳤습니다. Python·일반 노트북 CPU 기준입니다.



설계 원칙	이유 / 적용
1. 기준 모델 우선	분류는 로지스틱→작은 LightGBM, 이상은 강건 편차/전역 IF를 각각 평가. 처음부터 점수를 평균하지 않음.
2. 관측 사실 보존	분리 선·반복·결측을 유지. 점별 시각이 없으면 순간 속도·가속도·체류시간 산출 불가.
3. 평가 상황 재현	조업 분류는 신규 선박, 이상탐지는 미래를 쓰지 않는 시간순·사건 평가.
4. 추가 효과 검증	조업/개인 기준·시간 규칙·RL은 한 요소씩 추가하고 효과·비용을 확인.

통합 기준

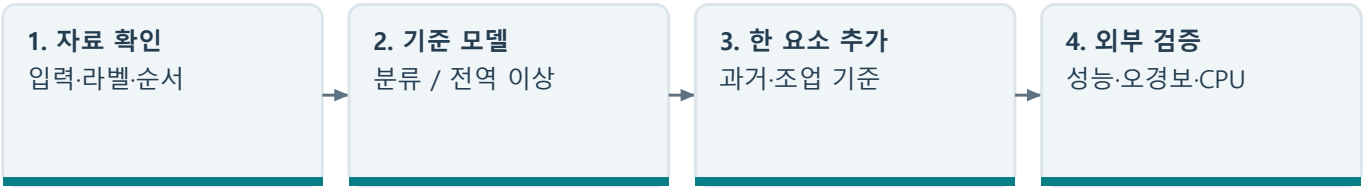
상세 개념은 V1에서 복원했습니다. 상충하는 결합·지표·일정 표현은 V2의 수정 조건을 반영했습니다. 기존 검토 이력은 실행 지침에 흡수하여 이 파일만 읽어도 사용할 수 있도록 정리했습니다.

[확인된 한계] 샘플은 10척·10행입니다. 두 클래스는 각각 한 척이고 사고/연속 이력이 없습니다. 아래 설정은 검증 전 제안이며 최적 알고리즘·성능·현실 사고 예방 효과를 입증한 결과가 아닙니다.

사실·제안·가정을 구분해서 읽기

이 문서의 시작 설정·창 길이·표본화 간격은 실제 최적화 결과가 아닙니다.

표시	의미
확인된 사실	첨부 공지·양식·샘플 또는 공식 기술 문서에서 직접 확인한 내용.
설계 제안	구현·검증할 계획. 이 데이터에서 성능 우위가 입증된 결과가 아님.
가정 / 추론	확정되지 않은 조건 또는 가능한 해석. 조건이 바뀌면 설계·해석도 수정.



자료 상황	수행 가능한 단계	수행하면 안 되는 주장
현재 샘플	입력 점검·선 분리·기하 처리 확인	신뢰 가능한 4종 F1, 사고 탐지 성능
정식 조업 라벨	신규 선박 분류 검증	ID 암기 성능을 신규 선박 성능으로 해석
사고시각·시간 이력	약한 라벨·사전 탐지 창의 민감도 분석	사고 주변 모든 항적을 실제 이상으로 단정
검증된 경보 환경/로그	선택적 경보 정책 학습	replay 보상 개선을 실제 사고 감소로 해석

읽는 순서: 자료 3-4쪽 → 전처리·특징 5-8쪽 → 분류 9-11쪽 → 이상탐지·이력 12-15쪽 → 라벨·지표·시간 16-19쪽 → 강화학습 20-21쪽 → 경량화·실험·코드·출력 22-25쪽 → 팀 설명 26쪽 → 출처 27쪽.

샘플 10행의 전체 점검

[확인된 사실] 10척 모두 2025-01-01, rfid_time=0. 사고정보·점별 시각·연속 이력 없음. [S5]

샘플	조업형태	점 수	선 수	연속 중복	선 내부 길이(m)
1	자망	4	1	0	24.6
2	자망	18	1	0	3062.3
3	연안복합	7	2	1	85.0
4	통발	2	1	0	8.0
5	연안복합	126	6	107	132.5
6	채낚기연승낚시	18	1	14	2.2
7	자망	17	1	11	4.7
8	연안복합	18	1	12	3.4
9	자망	18	1	0	176.7
10	연안복합	18	1	13	6.0

1. 컬럼

5개 의미 컬럼 뒤에 7개 빈 헤더 열이 있으며 모두 비어 있습니다. UTF-8 BOM. 의미 컬럼의 빈 값과 (선박·날짜·시간) 중복 키는 확인되지 않았습니다.

2. 기하 구조

16개 구성 선·246개 점. 선 내부 인접 쌍은 246-16=230개이고, 동일 좌표가 연속된 쌍은 158개(68.7%)입니다. 연속 중복 압축 후 88개 점이 남으며 이는 전체 고유 좌표 수와 다릅니다.

3. 검증 한계

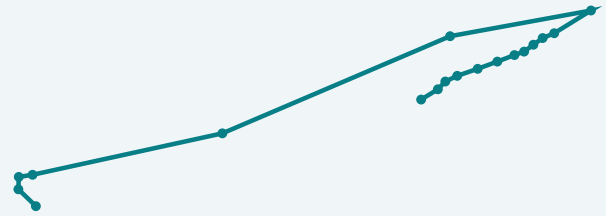
통발·채낚기연승낚시는 각 한 척. 선박 단위로 나누면 해당 클래스의 학습 또는 검증이 없어 신규 선박 성능을 검증할 수 없습니다.

길이는 구성 선 내부의 Haversine 구면 근사 합입니다. 관측 선 길이는 실제 총 운항거리와 다를 수 있습니다. 공지 예시 연도 2026과 샘플 연도 2025의 차이는 기록하고 원문을 보존합니다.

실제 샘플 그림: 무엇을 알 수 있나

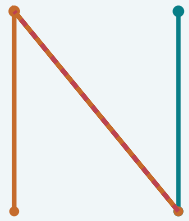
[확인된 사실] 실제 좌표를 지역 평면으로 옮겼습니다. 패널마다 축척이 다릅니다.

샘플 2 · 자망
18점 / 1개 선 / 중복 0회



동서 범위 약 2114.8m / 남북 약 722.6m

샘플 3 · 연안복합
7점 / 2개 선 / 중복 1회



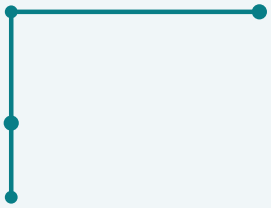
동서 범위 약 15.2m / 남북 약 18.5m

샘플 5 · 연안복합
126점 / 6개 선 / 중복 107회



동서 범위 약 8.7m / 남북 약 18.3m

샘플 6 · 채낚기연승낚시
18점 / 1개 선 / 중복 14회



동서 범위 약 1.2m / 남북 약 0.9m

그림에서 확인	해석의 한계
3번: 선 내부 길이 약 85m. 두 선 연결 시 가상 길이 약 24m 추가.	붉은 점선은 관측되지 않은 연결. 서로 다른 선 사이에 방향·거리 특징을 만들지 않음.
5번: 126점, 6개 선, 연속 중복 107회.	반복 수는 관측 구조. 점별 시각이 없어 체류시간으로 환산 불가.
6번: 길이 약 2.2m, 매우 작은 공간 범위.	[추론] 정지/위치 흔들림 가능성. 정지나 특정 조업행동으로 확정할 근거는 부족.

색은 구성 선, 점 크기는 같은 좌표의 반복 수입니다. 이 시간대의 조업 라벨은 곧 "현재 실제로 조업 중"이라는 라벨은 아닙니다. 운항·대기 상태는 샘플에 따로 제공되지 않았습니다.

전처리의 조건을 먼저 고정하기

[설계 제안] 입력 계약이 확정되기 전에는 계산 가능한 값과 해석 가능한 값을 구분합니다. [R10]

처리 단계	확인·처리	잘못된 대체
1. 스키마	ID 문자열, 실제 날짜·0-23 시간. Train 라벨 필수 /Test는 라벨 비필수.	추가 컬럼 일괄 삭제, 날짜 연도 자동 변경
2. WKT·좌표	형식·유형·빈 선·좌표 유한성 검사. X=경도/Y=위도. CRS 확인.	degree 길이를 m로 사용, 파싱 실패 행을 조용히 누락
3. 구성 선	원래 선 경계 보존. 순서의 시간 의미는 별도 확인.	다른 선의 끝/시작을 연결, line_merge로 시간순서 추정
4. 연속 중복	형상용 압축 + 원본 수/중복 특징 유지. 모두 같은 점이면 형상 계산 분기.	압축 후 1점을 유효 LineString으로 억지 변환
5. 결측·단절	유효한 0과 계산 불가 NaN 구분. 실패 사유·결측 표시·행 키 보존.	결측을 정지 0으로 변환, 큰 단절을 선으로 보간
6. 잡음	극소 벡터·큰 점프를 표시하고 원본/제한 정제 결과 비교.	사고 신호까지 없애는 무조건 평활화·삭제

순서와 시간은 같은 정보가 아닙니다

WKT는 선의 기하 좌표 순서를 담지만 점별 시각을 담지는 않습니다. 공간 굴곡은 계산할 수 있어도 급선회 속도·가속도는 계산할 수 없습니다. 구성 선 목록의 순서를 전체 운항 시간순으로 단정하지 않습니다.

정식 분석은 지리 거리(pyproj.Geod) 또는 적절한 지역 미터 좌표계를 사용합니다. 위경도 범위만으로 CRS를 확정하거나 여러 투영대의 좌표를 그대로 한 평면에 섞지 않습니다.

기본 특징: 정의와 계산 조건

[설계 제안] 소수의 재현 가능한 특징부터 구현합니다. 특징 수는 완료 기준이 아닙니다.

그룹	처음 구현할 값	계산 조건
길이·범위	L=선 내부 거리 합, 선별 길이 분위수, bounding box 폭/높이, 최대 범위	구성 선 사이 길이 제외. 관측된 선 길이로 명명.
직선성	구성 선별 D/L과 길이 가중 평균	D=해당 선 양 끝 거리. L 0일 때 NaN.
공간 굴곡	선 내부 절대 회전각 중앙값/상위 분위수, 원형 방향 분산	0/극소 벡터 제외. 유효 각도 수 함께 저장. 운항 순서 미확정이면 공간 특징으로만 해석.
공간 분포	장축/단축 분산, convex hull 면적, 길이 가중 중심	MultiLineString 자체 면적은 0. 포락 면적은 별도 hull의 면적. 퇴화 형상 분기.
품질	점 수·구성 선 수·연속 동일 좌표 쌍 비율·유효 벡터 수	분류/행동 특징과 별도 그룹. 수집 특성의 암기 여부 검사.
조건부 확장	거리 격자 점유·다중 규모, 과거 1/3/6시간 차이	격자 크기·시각 순서·이력 사용 조건을 확인한 경우에만.

숫자 0을 넣으면 안 되는 예

1. 2점 선

회전각이 없어 계산 불가입니다. "회전각 0"을 넣으면 실제 직선 항적과 섞입니다. NaN과 유효 각도 수를 저장합니다.

2. 한 위치에 반복된 선

길이 0은 가능한 관측값입니다. 직선성 D/L은 0/0이므로 NaN입니다. 반복 수는 보존합니다.

점별 시각이 없으면 순간 속도·가속도·정지시간은 산출하지 않습니다. L/1h를 사용한다면 "시간당 관측 경로 길이" 대리지표로 명명하고 관측 커버리지 한계를 표시합니다.

확장 특징을 계산할 때의 예시

[설계 제안] V1의 방향·회귀·공간 분포 설명을 보충합니다. 추가 특징은 검증 후 채택합니다.

예시 관측: A, A, A, B, C
점별 시각 없음. A의 반복 횟수는 체류시간이 아님.

형상 경로: A → B → C
선 내부 연속 중복 압축 길이·방향·직선성 계산

품질 경로: 원래 5점 유지
인접 쌍 4개 중 중복 2개 중복 비율 = 2/4 = 0.5

확장 특징	계산 방법	해석 조건
회전각	같은 구성 선에서 연속한 유효 벡터의 각도 차이. ±180° 경계를 순환 처리.	순서가 운항 순서인지 미확정이면 공간 굴곡으로만 표현. 시간당 회전율 아님.
방향 분산	유효 방향 θ의 평균 sin·cos로 R을 구하고 1-R로 요약. 길이 가중 여부 명시.	짧은/0벡터 제외. R 0이면 대표 방향이 불안정.
재방문·엔트로피	거리 표본화 후 격자 점유 비중 p로 -Σp log p. 반복 방문 규칙과 격자 크기 고정.	공간 점유의 복잡도. 체류시간 엔트로피로 명명하지 않음.
장축·단축	지역 미터 좌표의 분산/PCA. 실제 m 규모와 크기 정규화 표현을 별도 계산.	거의 정지·단축 0이면 비율과 장축 정렬을 마스크.

1. 표본화로 길이가 바뀔 수 있음
굴곡 경로를 드문 점으로 뽑고 직선 연결하면 원래 선보다 짧아질 수 있습니다. 원본 선 내부 길이와 재표본 근사 길이를 따로 저장하고, 선 사이를 연결하지 않습니다.

2. 정규화와 절대 위치
상대 형상은 위치 차이를 줄이는 후보지만 실제 조업 규모·진행 방향 신호도 잃을 수 있습니다. 실제 크기/정규화/절대 위치 포함 모델을 동일 분할과 새 해역에서 비교합니다.

거리 간격·격자·짧은 벡터 기준은 정식 Train의 분포와 센서 조건에서 정합니다. 샘플 2m 경로에 25m 간격을 강제로 적용하는 식의 일괄 규칙은 피합니다.

전처리 아이디어를 반례로 점검

[추론/제안] 아래 효과는 가능성입니다. 기존 기법 조합의 연구 신규성·이 대회에서의 우위는 미검증입니다.

아이디어	검증할 기대 효과	실패할 수 있는 경우
형상/품질 분리	반복 압축·거리 표본화로 관측 밀도의 영향을 줄임.	압축·표본화가 짧은 움직임을 지움. 품질 특징이 선박/수집 장치의 대리 ID가 됨.
실제 크기 + 정규화	해역·선박 규모 차이에 덜 민감한 형상 비교.	방향·크기가 조업 구분에 필요한 정보이면 성능 하락. 정지 항적 정규화는 잡음을 확대.
다중 공간 규모	작은 굴곡과 큰 경로 구조를 함께 비교.	25/100/400m 간격은 2m 항적에 부적합. 규모 후보는 정식 Train 분포에서 정함.
집단/개인 비교	평소와 다른 변화와 일반적 패턴을 함께 봄.	개인 기준이 이상을 학습하거나 공통 변화로 개별 사고를 정상화함.

1. 표본화 규칙
각 구성 선 내부에서만 수행합니다. 끝점·원래 선 길이를 보존합니다. 재표본 점을 직선 연결한 근사 경로와 원본 길이를 구분합니다.

2. 비교 방식
같은 분할·같은 모델로 한 전처리만 바꿉니다. 짧은 항적·희귀 클래스·신규 선박별 성능과 특징 추출시간을 따로 확인합니다.

3. 채택 조건
전체 평균만 좋아지고 짧은 항적의 미탐지가 늘면 자동 채택하지 않습니다. 목적과 공식 지표를 기준으로 손실·개선을 명시합니다.

> **주변 선박·기상 정보**
> 외부 데이터와 동시간대 다른 선박 사용은 허용 범위를 확인한 선택 실험입니다. 기본 제안은 제공 항적만으로 완결되도록 구성합니다.

과제 1: 작은 기준 모델부터

[설계 제안] LightGBM의 우위는 가정이며, 동일 검증의 로지스틱 회귀와 비교합니다. [R4,R5]

순서	모델/처리	목적
1	최다 클래스 예측 기준	불균형 데이터에서 의미 없는 Accuracy를 구별.
2	결측 대체+결측 표시+스케일링+로지스틱 회귀	작고 해석 가능한 지도학습 기준.
3	같은 특징의 작은 LightGBM	비선형 관계가 신규 선박에서 도움이 되는지 확인.
4	확률 검증·필요 시 보정	출력 확률의 과신을 점검. 단순 softmax가 정확한 신뢰도를 보장하지 않음.

LightGBM 시작 후보: 최적 설정 아님

설정	후보 / 적용 조건
objective / class 수	multiclass. 클래스 목록은 정식 라벨에서 확정.
learning_rate / n_estimators	0.05 / 상한 300. 내부 그룹 검증으로 조기 종료 30회 후보.
num_leaves / max_depth	15 / 4부터. 필요할 때 31 / 6 비교.
min_child_samples / reg_lambda	50 / 1 후보. 적은 학습량에서는 50이 지나칠 수 있어 조정.
특징·행 표본화	처음에는 1.0. 필요 시 0.8 비교. 행 subsample 사용 시 subsample_freq>0 필요.
CPU / seed	n_jobs=4 후보. 실제 CPU·다른 작업 부하에 맞춰 조정. seed=42 기록.

선박 ID는 특징 제외. class_weight·선박별 가중치는 선택 실험이며 확률을 왜곡할 수 있습니다. 가중치×sample_weight가 중복 적용되는지도 확인합니다. [R4,R5]

추가 알고리즘은 대안으로 비교

[설계 제안] V1의 후보 목록을 유지하되, 자동 앙상블로 확장하지 않습니다.

후보	비교할 상황	채택 전에 확인
로지스틱 회귀	기본 기하 특징의 작은 기준. 결측 대체·표시·스케일링.	복잡한 후보가 개선되는지 판단할 기준.
LightGBM	기하 특징 사이 비선형 관계. 작은 잎/깊이부터.	신규 선박 성능·확률·전체 CPU 비용.
Random Forest / CatBoost	같은 특징·같은 그룹 분할에서 별도의 대안 후보.	파일 크기·추론 시간 대비 추가 효과. 전부 결합할 이유는 없음.
작은 1D CNN / GRU	연속 이력이 충분하고 순서·마스크·가용시각이 정의된 경우.	우선 현재 특징+과거 요약과 비교. 충분한 독립 선박/사건 필요.

시간순 모델을 쓰는 경우의 최소 구성

1. 입력 단위
시간별 특징 벡터의 최근 창을 사용합니다. 과거 6시간은 예시 후보이며 최적값이 아닙니다. 실제 경과시간·관측 결측·유효 시간 수를 함께 넣고 미래 시간은 사용하지 않습니다.

2. 가벼운 후보
한 층의 작은 GRU 또는 작은 1D CNN을 비교 후보로 둡니다. 장치/구현별 파일·메모리·추론 비용은 실측합니다. 파라미터가 적어도 데이터가 부족하면 과적합할 수 있습니다.

3. 공정한 비교
트리에도 동일한 과거 요약을 주어 "시간 정보 추가 효과"와 "신경망 효과"를 구분합니다. 같은 선박·기간 분할과 동일 CPU 조건으로 평가합니다.

> **불균형 처리**
> 클래스/선박 가중치는 내부 학습에서만 산출하고 별도 선택 실험으로 비교합니다. 원시 항적을 단순 SMOTE로 합성하면 선 구조와 실제 경로 제약을 보장하기 어렵습니다. 가중치 사용 후 확률 과신·희귀 클래스 Recall을 함께 점검합니다.

단일 모델을 먼저 선정합니다. 앙상블은 서로 다른 오류를 줄이는지 추가 검증하고, 성능 이득이 작으면 크기·비용이 낮은 단일 모델을 유지합니다.

과제 1 검증: 선박 분리가 우선

[확인된 원칙] Test A 신규 선박 조건에 맞춰 동일 ID를 학습·검증에 함께 넣지 않습니다. [S2,R2]

1. 잠근 평가 선박
최종 평가용 선박을 먼저 떼고 목록을 저장합니다. 설정·특징·임계값 선택에 해당 정답을 사용하지 않습니다.

2. 내부 그룹 검증
나머지 선박에서 StratifiedGroupKFold 등으로 특징·복잡도·가중치를 비교합니다. 모든 학습 fold의 클래스 목록을 검사합니다.

3. 확률 보정
별도 보정 선박 또는 그룹 OOF 예측을 사용합니다. OOF는 "그 선박을 학습하지 않은 모델의 예측"입니다. 기본 cv를 그대로 써서 같은 선박이 섞이지 않게 합니다.

4. 최종 평가·재학습
선택을 고정한 뒤 평가 선박에서 한 번 확인합니다. 그 후 허용된 전체 Train으로 재학습하며, OOF 보정기와 최종 모델의 점수 분포 차이를 기록합니다.

보고할 값	해석
클래스별 F1·Recall·표본/선박 수	희귀 클래스가 평균에서 숨겨지는지 확인.
Macro-F1 + 공식 지표	Macro-F1은 내부 진단 제안. 공식 지표라고 단정하지 않음.
확률 보정 전/후 + 오류 사례	예측 확률, log loss, reliability 확인. 새 선박·해역의 낮은 신뢰도 사례 기록.

한 클래스에 선박 한 척이면
그 선박을 검증에 넣으면 학습에 해당 클래스가 없습니다. 학습에 넣으면 그 클래스의 신규 선박 검증이 없습니다. fold를 5→2로 줄여도 해결되지 않습니다. 현재 샘플의 통발·채낚기연승낚시가 이 경우입니다.

클래스가 부족하면 정식 데이터 수령 후 분할을 다시 설계합니다. 학습이 불가능한 fold를 다른 문제의 성능과 섞어 평균하지 않습니다.

과제 2 검증: 시간순 재현

[설계 제안] 기존 선박의 미래 탐지와 신규 선박의 초기 탐지를 별도 평가합니다.

검증 상황	허용할 정보	분리할 결과
기존 선박의 미래	허용된 과거 원시 항적·요약값. 현재를 점수화하기 전의 기준.	이력 있는 선박의 탐지율·오경보·지연.
신규 선박 초기	학습 선박의 전역/조건 기준. 제공·허용된 Test 과거만.	이력 없는 초기와 이력 축적 후를 구분.
사고 사건 단위	같은 사고의 양성 창·사고 후 창은 한 평가 묶음.	사고 전 성공과 사고 후 반응을 따로 집계.

1. 시간 블록 고정
모델 적합 기간 → 설정·점수 보정 기간 → 잠근 평가 기간 순으로 정합니다. 가능한 사건 수를 먼저 세고 각 기간에 무엇이 포함되는지 기록합니다.

2. 경계 누수 제거
사고 전후 라벨 창이 학습/평가에 겹치는 표본은 제외합니다. 반면 추론 시 허용된 과거 이력은 평가 시작의 워밍업에 사용할 수 있습니다. 두 종류의 경계를 혼동하지 않습니다.

3. 시간순 실행
현재 특징 → 현재 점수 → 이후 기준 갱신 순으로 replay합니다. centered rolling, 미래 보간, 평가 전체의 통계로 과거를 정규화하지 않습니다.

4. 개인 기준 오염 검사
고점수·저품질 구간의 갱신 지연과 기준 고정 기간을 비교합니다. 최근 구간이 실제 정상이라고 가정하지 않고, 이력이 부족하면 전역 기준으로 돌아갑니다.

같은 선박의 과거가 미래 탐지에 쓰이는 것 자체는 누수가 아닙니다. Test 이력 사용이 허용되어 있고 미래·평가 정답으로 모델을 튜닝하지 않는 조건을 충족해야 합니다.

이상점수의 최소 기준 모델

[설계 제안] 강건 편차와 Isolation Forest를 각각 평가한 뒤 결합 필요성을 판단합니다. [R3]

단계	구현	실패 방지
1. 기준 자료	알려진 사고 주변을 제외한 정상 후보를 선정. 제외 창은 설정 기간에서 결정.	사고가 미등록된 구간도 있으므로 확인된 정상과 구분.
2A. 강건 편차	|x-median|/(1.4826×MAD+ε), 특징 그룹별 요약.	MAD=0·유효 특징 부족 시 분기. 사고 확률로 해석하지 않음.
2B. Isolation Forest	100개 트리·max_samples=min(256,n_train) 시작 후보. 원시 점수=-score_samples.	표본 수가 충분한 정식 데이터에서 학습. 점수 방향 확인.
3. 결측 처리	Train에서 대체값 적합+결측 표시. 모델이 지원하는 결측 경로 확인.	전부 결측인 특징·행을 0으로 숨기지 않음.
4. 0-1 점수	고정된 별도 기준 집합의 ECDF로 원시 점수를 순위화.	Test를 보고 min-max 조정하지 않음. 작은 기준 집합의 분해능 기록.

0.95 점수의 뜻과 한계

1. 표현
기준 집합 원시 점수의 약 95%보다 크다는 상대적 순위입니다. "사고 확률 95%"가 아닙니다.

2. 가정
기준 집합의 시간·해역·품질 분포가 달라지면 같은 점수의 오경보 빈도도 달라질 수 있습니다.

3. 분해능
기준 표본이 20개면 경험적 순위가 약 0.05 간격입니다. 0.951과 0.952의 차이를 정밀한 위험 차이로 설명할 수 없습니다.

contamination은 실제 사고율의 추정치가 아닙니다. IF 기본 predict 임계값 대신 연속 점수를 유지하고, 경보 임계값은 별도 검증으로 결정합니다. [R3]

조업형태 조건이 이상을 숨길 수 있다

[설계 위험에 대한 추론] 현재 항적으로 분류와 이상 기준을 동시에 바꾸는 경로를 검증해야 합니다.

가정 예시: 같은 선박의 현재 항적이 평소와 달라짐
숫자는 설명용이며 샘플에서 학습하거나 측정한 값이 아님.

고정된 과거 기준
평소 조업형태 A 대비 이상점수 0.90

현재 항적으로 기준 변경
현재를 B로 분류 → B 기준 점수 0.20

1. 문제

평소 A 선박이 이상 움직임을 보였을 때 현재 분류기가 B라고 판단하면, B의 일반 패턴과 비교하여 이상점수가 낮아질 수 있습니다. 이는 가능한 실패 사례이며 실제 발생 빈도는 미검증입니다.

비교할 설계	장점	주의점
전역 기준만	현재 분류 변화로 기준이 바뀌지 않음.	정상 조업 간 차이를 이상으로 볼 수 있음.
허용된 과거 조업 기준	현재 이상과 분류 기준의 즉각적 동시 변화 완화.	과거 오분류·실제 조업 전환에는 늦게 적응.
현재 확률 혼합	현재 조업 상황을 반영하는 후보.	이상을 정상화할 위험. 자동 주력 채택 금지.

권장 검증안
전역 이상 채널을 유지합니다. 과거·조업 조건 점수는 부가 채널로 먼저 평가하고, 현재 분류가 바뀐 사건의 미탐지를 따로 분석합니다. max 결합도 오경보를 늘릴 수 있어 검증 후에만 적용합니다.

조업 라벨을 알고 있는 Train의 기준 생성과, 정답이 없는 Test의 기준 선택은 다릅니다. 검증 정답 fishing_code를 라우팅에 사용하는 "정답 조건 모델"을 제출 성능으로 보고하지 않습니다.

개인 과거 기준과 시간 규칙의 결합

[설계 제안] V1의 실행 순서를 복원하고, V2의 기준 오염·가용시각 조건을 적용합니다.

단계	구현 예시	검증할 위험
1. 허용 이력	선박의 t 이전 유효 항적. 최근 24-72개 관측 또는 7일은 창 후보.	행 수와 실제 시간폭이 다름. 결측·공백·시간차를 별도 저장.
2. 현재 대비	과거 중앙값/MAD 대비 현재 특징의 편차. 이력 부족 시 전역 기준.	최근이 정상이라는 보장 없음. 계절/실제 조업 전환과 이상 구분.
3. 선택적 결합	별도 기준에서 0-1로 변환. a=(1-w)a_global+w a_self를 비교 후보로.	w는 내부 설정에서 결정. 평균이 높은 전역 이상을 희석할 수 있음.
4. 사후 갱신	현재 점수 저장 후 허용된 이력 상태 갱신. 고점수/저품질 갱신 지연 비교.	빠른 갱신은 이상을 정상화, 긴 동결은 정상 변화에 적응 실패.

시간 일관성을 주는 작은 규칙

규칙	예시	비용
EWMA	z_t=αa_t+(1-α)z_(t-1). 과거와 현재만 사용.	잡음 감소 대신 단발 사고 신호와 사전 탐지 지연 가능.
히스테리시스	높은 임계값으로 시작, 낮은 임계값으로 해제.	반복 경보 감소 대신 해제 지연.
지속·쿨다운	연속 조건 또는 일정 기간 재경보 제한. 규칙은 내부 설정에서 고정.	짧은 이상·연속 사건의 미탐지 가능.

시간대 t의 처리 순서
입력 품질 검사 → 현재 특징·전역 점수 → 허용된 과거 기준 비교 → 원시/선택적 평활 점수 저장 → 경보 규칙 → 이력 상태 갱신

낮은 품질을 정상 점수 0으로 바꾸지 않습니다. 품질 표시와 행동 변화 근거를 별도로 남기고, 원시 점수·결합 점수·평활 점수의 효과를 각각 평가합니다. Test 이력 활용 허용 조건을 먼저 확인합니다.

사고시각만으로 정답을 만들 수 있나

[확인된 한계] 사고 발생시각은 이상 시작시각이나 정확한 정상/이상 라벨을 대신하지 않습니다.

라벨 수준	가능한 평가	해석 범위
정확한 이상구간·정상 확인	시간별 TP/FP/FN/TN·F1·AP + 사건 사전 탐지	해당 라벨 정의에 대한 탐지 성능.
사고시각만 제공	사고 전 1/3/6시간 등의 약한 라벨 창 민감도, 사전 탐지율	정의한 창의 proxy-F1. 실제 이상구간 F1로 부르지 않음.
일부 사고만 알려짐	알려진 사건의 탐지 사례, 비사고 구간 경보 빈도	미등록 사고가 있어 모든 비사고 구간을 진짜 음성으로 확정 불가.
사고/이상 라벨 없음	순위·사례 검토·입력 스트레스 테스트	사고 탐지 F1·실제 사고 확률을 검증할 수 없음.

1. 연결 정보
사고 ID·선박 ID·시각의 시간대·정확도·유형을 확인합니다. 한 선박에 여러 사건이 있으면 중복 연결 규칙을 기록합니다.

2. 시간 구간
사고 전·사고 포함·사고 후 시간대를 분리합니다. 관측 부족·라벨 충돌·시각 불확실 구간은 평가 가능성과 제외 사유를 함께 기록합니다.

3. 과도한 음성 확정 방지
사고가 기록되지 않았다는 사실만으로 정상임을 증명할 수 없습니다. "정상 후보"의 경보는 확인된 FP와 구분해서 보고합니다.

> **단위의 착각**
> 사고 3건 주변에서 300개 시간창을 만들더라도 독립적인 사건은 3건입니다. 시간행 수를 사건 수처럼 제시하지 않습니다. 사건이 매우 적으면 수치와 신뢰구간의 해석도 제한됩니다.

TP·FP·FN·TN과 F1의 계산

[설명 예시] 아래는 정확한 시간별 이상/정상 라벨이 있다고 가정한 가상 1,000행입니다. [R1]

	예측: 이상	예측: 정상
실제: 이상	**TP = 15** 이상징후를 탐지	**FN = 5** 이상징후를 놓침
실제: 정상	**FP = 30** 정상을 이상으로 경보	**TN = 950** 정상을 정상으로 판단

계산식

Precision=TP/(TP+FP) · Recall=TP/(TP+FN)

F1=2TP/(2TP+FP+FN) · Accuracy=(TP+TN)/전체

지표	예시 계산	의미
Precision	15/45 = 0.333	경보 중 실제 이상인 비율
Recall	15/20 = 0.750	실제 이상 중 탐지한 비율
F1	30/65 = 0.462	정밀도와 재현율의 조화 평균. TN은 직접 포함하지 않음.
Accuracy	965/1,000 = 0.965	정상이 많아 높게 나와도 미탐지·오경보가 존재.

다중분류는 클래스별 F1을 계산합니다. Macro는 클래스 동일 가중, Weighted는 표본 수 가중. 단일 정답 다중분류에서 Micro-F1은 통상 Accuracy와 같습니다. 라벨 목록·0 분모 처리·평가 제외 정책을 기록합니다.

양성이나 음성이 없는 평가 부분의 지표를 정상적인 성능 수치처럼 평균하지 않습니다. 약한 라벨로 계산하면 지표명과 설명에 그 정의를 포함합니다.

지표의 이름과 분모를 정확하게

[설계 제안] 공식 채점과 내부 진단을 구분합니다. 제공 공지에는 세부 지표·가중치가 없습니다.

지표	정의·사용 조건
AP (Average Precision)	average_precision_score로 계산. PR 곡선 사다리꼴 면적과 서로 다른 값이므로 "PR-AUC"라고 혼용하지 않음. [R11]
임계값 F1	정상/이상 라벨 정의와 별도 보정에서 정한 임계값을 명시. 시험 정답으로 최대 F1 임계값을 선택하지 않음.
사전 탐지율	정의한 사전 창에서 유효 경보가 있었던 사건 / 평가 가능 사건. 관측 부족 사건 수도 보고.
선행시간	사고시각 - 첫 유효 사전 경보 가용시각. 탐지 사건의 분위수와 미탐지 사건 수를 같이 보고.
경보 빈도	확인된 정상 관측시간 100시간당 경보 에피소드. 정상 미확인이면 "비사고 기록 구간의 경보 빈도"로 명명.

분모 예시: 시간행을 운항일로 바꾸면 생기는 문제

1. 가정 예시

정상으로 확인된 관측이 200시간이고 경보 시작이 5회이면 100시간당 2.5회입니다. 같은 경보가 여러 행에 이어지면 한 에피소드로 묶는 규칙을 미리 정합니다.

2. 불가능한 추정

이 200시간을 실제 운항시간이나 실제 운항일 수로 바꿀 근거가 없으면 "운항일당 오경보"라고 쓰지 않습니다. 누락 관측과 운항 여부는 별도 정보입니다.

> **사건·시간 지표를 섞지 않기**
> 한 시간만 맞혔다고 사건 전체 시간대를 정답으로 바꾸는 point adjustment는 시간별 F1을 과대평가할 수 있습니다. 원래 시간별 평가와 사건별 탐지율은 별도 표로 보고합니다. [R9]

조기 탐지는 “가용시각” 기준

[가정 예시] 시간대는 [h,h+1), 데이터·계산 지연은 합계 5분이라고 가정합니다. 실제 조건은 미확정입니다.



정보	예시 값	경보에 사용할 수 있는 시점
사용 항적	[09:00,10:00)	10:00 종료 + 지연 5분 = 10:05
사고	10:20	사전 경보 선행시간 = 15분
다음 항적	[10:00,11:00)	11:05 이후. 10:20 사고의 사전 경보로 계산 불가

1. 확인할 항목
part_dt의 기준 날짜, rfid_time의 구간 의미, 데이터 시간대, 항적 생성·수집 지연을 확인합니다. 사용자의 시간대가 데이터 시간대와 같다고 자동 가정하지 않습니다.

2. 평가 시점
모델 입력이 완성된 시점과 실제 결과 가용시점을 기록합니다. 사고가 시간대 안에서 발생했으면 해당 전체 항적으로 사고 전 탐지를 주장하지 않습니다.

3. 불확실한 시각
사고시각이 분/시간 수준으로 불확실하면 선행시간을 지나치게 정밀한 숫자로 제시하지 않습니다. 가능한 범위 또는 시간대 단위 결과를 보고합니다.

시간별 완성 항적만 있으면 시간대 내부의 실시간 탐지 성능을 복원할 수 없습니다. 더 빠른 탐지를 연구하려면 부분 항적·점별 시각 또는 더 짧은 집계 단위가 필요합니다.

강화학습을 주력으로 쓸 근거는 부족

[판단/추론] 현재 자료의 분류·이상점수 문제에는 지도/비지도 기준을 먼저 검증하는 편이 타당합니다.

상황	권장 판단	이유·조건
조업 라벨 예측	지도학습 우선	예측 행동에 정답 보상을 주는 한 단계 구성은 지도학습을 더 복잡하게 구현하는 셈.
항적 이상점수	강건 기준/IF 우선	현재 CSV에 경보 행동·보상·결과 로그가 없음.
쿨다운·자원 제약 경보	순차 정책 실험 가능	현재 경보가 미래 경보 상태/비용을 바꾸는 환경을 명확히 정의.
실제 항로·회피 제어	현재 자료로 평가 불가	행동·주변 상황·동역학·결과 또는 검증된 환경 필요.

알고리즘별 필요한 자료

1. 작은 Q-learning
유한한 상태·대기/경보 행동·보상을 정의한 연구용 replay가 있을 때. 먼저 고정 임계값+쿨다운과 비교합니다.

2. CQL 또는 IQL
실제 상태·행동·보상·다음 상태 로그가 있을 때 후보입니다. 데이터에 없는 행동, 결과, 숨은 교란, 행동 선택 편향을 자동 해결하지 않습니다. [R6,R7]

3. PPO
상호작용할 수 있고 행동 결과가 타당한 환경이 있어야 합니다. 정적 CSV만으로 바로 적용하는 알고리즘으로 추천하지 않습니다. [R8]

경보가 이후 의사결정 상태를 바꾸지 않으면 고정 임계값·비용 민감 분류가 더 단순한 비교군입니다. 여러 알고리즘을 결합할 수 있다는 사실이 결합의 필요성을 증명하지는 않습니다.

강화학습의 작은 경보 실험 예시

[설계 제안] 핵심 과제 완료 후의 선택 실험입니다. 환경·상태·보상을 모두 가정합니다.

항적 모델
연속 이상점수

→

고정 규칙 / Q학습
대기 또는 경보

→

연구용 평가
동일한 오경보 제약

가정: 행동은 경보 상태에만 영향
실제 궤적·사고 여부는 관측된 그대로. 사고 예방 효과를 측정하는 환경이 아님.

요소	구체적인 시작 예시
상태	점수 3단계 × 점수 추세 3단계 × 품질 2단계 × 쿨다운 2단계 = 36상태. 구간 경계는 학습/설정 기간에서 고정.
행동	대기/경보 2개. 36×2=72개 Q값. 쿨다운 중 경보의 허용·패널티 규칙을 명시.
보상	정의한 사전 창의 최초 경보 보상, 반복·비사고 구간 경보 비용, 사건 종료 시 미탐지 비용. 한 사건에 반복 보상 금지.
자료 사용	미래 사고시각은 학습 보상 계산에만 사용 가능. 정책의 현재 입력·평가 시 행동 선택에는 사용 불가.
비교	같은 점수·품질·쿨다운을 쓰는 고정 임계값/시간 규칙과 비교. 동일한 경보 빈도 제약 아래 사건 사전 탐지·지연 평가.

이 실험이 증명하지 못하는 것
replay의 경보는 실제 항로와 사고 여부를 바꾸지 않습니다. 약한 라벨·정한 보상에서의 경보 효율만 평가합니다. 요약 상태가 충분한 Markov 상태라는 보장도 없으므로 반복 검증이 필요합니다.

대회 제출 연속 이상점수는 별도로 유지합니다. 작은 Q-table의 결과가 규칙보다 개선되지 않으면 DQN·PPO로 키울 근거가 부족합니다. 전체 미래 라벨을 아는 최적 경보는 현실 정책과 공정한 비교군이 아닙니다.

크기는 숫자 목표보다 측정이 먼저

[설계 제안] 성능·오경보·CPU 비용을 같이 비교합니다. 대회의 모델 크기 제한은 제공 자료에서 확인되지 않았습니다.

방법	적용 순서	측정할 부작용
특징 축소	불안정·중복 특징과 추가 그룹을 제거 실험.	분류/짧은 항적/사고 성능 손실.
트리 제한	leaves·depth·rounds를 제한하고 조기 종료.	희귀 클래스와 기간 이동 성능.
모델 수 제한	전역 1개부터. 선박별 모델 대신 과거 요약값.	조건별 차이를 놓치는지 확인.
캐시·청크	WKT를 매번 파싱하지 않고 특징 캐시.	전역 정렬·중복 검사·청크 경계 이력 누락.
증류·양자화	기준보다 필요성이 확인된 경우만.	정확도·확률·호환성과 실제 CPU 속도.

숫자로 확인할 수 있는 범위

1. 특징 메모리 계산

100만 행×40개 float32×4B=160MB는 특징 배열만의 계산입니다. CSV 문자열·DataFrame·정렬 복사·모델·이력 메모리는 포함하지 않습니다.

2. 트리 수 계산

다중분류는 클래스 수×boosting rounds만큼 트리를 생성합니다. 4종×300회이면 1,200개입니다. 실제 저장 크기는 직접 측정합니다. [R4]

3. CPU 측정

같은 CPU·스레드·배치·워밍업 조건으로 특징 추출/모델 추론/전체 시간을 나누고 p50·p95·최대 메모리를 보고합니다. 실측 전 "실시간"이라 단정하지 않습니다.

> **선정 기준**
> 25MB 같은 임의 상한을 대회 기준처럼 쓰지 않습니다. 검증 성능이 비슷하면 더 작은 모델을 선택하고, 허용할 성능 손실·오경보 변화는 실험 전에 명시합니다.

추가할 실험에는 채택 기준이 필요

[설계 제안] 기본 모델을 고정하고 한 요소씩 비교합니다. 여러 변경을 한 번에 합치지 않습니다.

실험	비교	확인할 실패 사례
E0 입력	원본·압축·예외 처리	2점·0길이·분리 선·결측·청크 경계
E1 분류	상수 기준 → 로지스틱 → LightGBM	신규 선박·클래스 누락·확률 과신
E2 위치/품질	형상만 vs 절대 위치/품질 추가	해역 이동·장치/선박 대리 ID
E3 전처리	반복 압축·거리 표본화·규모 하나씩	짧은 항적 손실·추출시간 증가
E4 이상	강건 편차 vs IF, 필요 시 결합	불완전 정상 기준·분포 이동
E5 조건 기준	전역 vs 과거 조업/개인 기준	현재 오분류가 이상을 숨김·이력 오염
E6 시간 규칙	원시 vs EWMA/쿨다운	오경보 개선 대신 사전 탐지 지연
E7 크기/RL	크기 축소, 핵심 완료 후 경보 정책	성능 손실·규칙보다 개선 없는 복잡화

1. 실험 기록
자료 버전·학습/보정/평가 범위·분할 ID·라벨 정의·파라미터·seed·출력 규격·CPU 조건을 저장합니다.

2. 최고값 편향 방지
평가 결과를 보고 반복 튜닝하지 않습니다. 설정은 내부 검증에서 고르고 잠근 평가를 마지막에 사용합니다.

3. 독립 단위 확인
선박/사건 단위 신뢰구간과 사례 수를 보고합니다. 사건이 극히 적으면 넓은 불확실성과 정량 결론의 제한을 명시합니다.

입력 코드도 Train/Test를 구분

[구현 예시] 빈 Unnamed 열만 제외하고, 사고정보 등 추가 의미 컬럼은 보존합니다.

```
import pandas as pd
def read_csv_checked(path, train=True):
    df = pd.read_csv(path, encoding="utf-8-sig",
                     dtype=str, keep_default_na=False)
    need = ["part_dt", "rfid_id", "rfid_time", "geom"]
    if train:
        need += ["fishing_code"]
    missing = set(need) - set(df.columns)
    if missing:
        raise ValueError(f"Missing columns: {missing}")
    blank = [c for c in df.columns
             if c.startswith("Unnamed:")
             and df[c].str.strip().eq("").all()]
    return df.drop(columns=blank)
```

다음 점검	검사
필수 값	빈 ID·날짜·시간·geom 검사. 날짜 파싱·시간 범위.
행 무결성	원래 행 순서·키 보존. 동일 키의 다른 geom/라벨 충돌 별도 처리.
형상	WKT 유형·CRS·선 경계·퇴화 형상·점 순서 조건 확인.
출력	공식 키·행 수·순서·클래스·유한 0-1 값·인코딩 검사.

입력 예시 검증 기록: Train=True로 10행·5개 의미 컬럼을 보존하고 빈 열 7개를 제외했습니다. 라벨을 제거한 복사본의 Test 읽기, 의미 있는 추가 컬럼 보존과 필수 컬럼 누락 오류도 점검했습니다. 이는 모델 학습·성능 검증이 아닙니다.

청크 읽기만으로 데이터가 전역 정렬되지는 않습니다. 시간순 이력 계산에는 선박·시간 정렬과 이전 청크의 이력 상태가 필요합니다. 원본 CSV는 변경하지 않습니다.

실행 흐름과 제출 파일 점검

[설계 제안] V1의 수령 직후 작업과 V2의 Train/Test 분기를 하나의 실행 절차로 정리했습니다.

단계	남길 결과	완료 기준
1. 자료 수령	파일 버전·컬럼·라벨·좌표계·시간/순서 정의·사고 연결표.	행/선박/클래스/기간 분포와 미확정 조건 기록.
2. 특징 생성	원래 행 키·순서, 구성 선/퇴화 분기, 특징·품질·실패 사유 캐시.	파싱 실패를 숨기지 않고 청크 경계/중복 키 확인.
3. 분류 학습	선박 그룹 분할, 기준/후보 모델, 보정 예측, 클래스별 오류 표.	평가 선박 정답으로 설정을 튜닝하지 않음.
4. 이상 학습	정상 후보 선정 규칙·독립 기준/점수 변환·이력 상태 초기값.	시간순 replay, 현재 점수 이후 갱신.
5. 최종 출력	Test A 분류/확률, Test B 연속 점수. 공식 템플릿으로 연결.	키·행 수·순서·유한 값·0-1 범위·라벨/확률 의미 검사.
6. 재현 패키지	실행 환경·seed·분할 목록·설정·코드·모델·보고서.	동일 입력의 재실행과 CPU/파일/메모리 측정.

제출 예시는 확정된 스키마가 아닙니다
공지의 "파일명 / 예측 조업형태 / 확률 / 이상점수"는 예시입니다. 실제 출력 단위가 파일·선박·시간행 중 무엇인지, 확률이 최댓값인지 전체 클래스 벡터인지, Test A/B 파일 분리 여부는 공식 템플릿으로 확인합니다.

1. 지금 할 수 있는 작업

샘플 구조·WKT·선 경계·반복/퇴화·입출력 검사와 설명 자료를 준비합니다. 실제 학습량·F1·사고 탐지율은 현재 샘플로 결정하지 않습니다.

2. 정식 데이터 이후 결정

각 클래스의 선박 수, 독립 사고 수, 라벨 수준과 평가 규칙을 확인한 뒤 분할·모델 복잡도·창 길이를 정합니다. 핵심 과제 완료 전에는 RL과 외부 자료 분석을 늘리지 않습니다.

제공 자료와 기술 출처

공식 문서·원 논문 확인일: 2026-10-12. 숫자 예시는 별도 가정이며, 모델 성능 실측은 수행하지 않았습니다.

S1-S5. 공지-문제개요.png, 공지-문제 과제.png, 공지-데이터 설명.png, 2026_참가신청서.hwp, 어선 과제 샘플데이터.csv. 공지·양식과 직접 계산한 샘플 통계를 우선 근거로 사용했습니다.

[R1] F1·평균 방식
https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html

[R2] 선박 그룹 분리
https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.StratifiedGroupKFold.html

[R3] IF 점수·contamination
https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.IsolationForest.html

[R4] LightGBM 설정·확률·트리 수
https://lightgbm.readthedocs.io/en/latest/pythonapi/lightgbm.LGBMClassifier.html

[R5] 독립 보정 자료·교차검증
https://scikit-learn.org/stable/modules/generated/sklearn.calibration.CalibratedClassifierCV.html

[R6] Kumar et al. (2020): CQL
https://arxiv.org/abs/2006.04779

[R7] Kostrikov et al. (2021): IQL
https://arxiv.org/abs/2110.06169

[R8] Schulman et al. (2017): PPO
https://arxiv.org/abs/1707.06347

[R9] Kim et al. (2022): 시계열 평가
https://arxiv.org/abs/2109.05257

[R10] WKT·구성 선·면적
https://shapely.readthedocs.io/en/stable/manual.html

[R11] AP와 사다리꼴 PR 면적
https://scikit-learn.org/stable/modules/generated/sklearn.metrics.average_precision_score.html

R4 추가: Parameters. R10 거리: pyproj Geod.

조업 조건이 이상을 숨기는 반례, 약한 라벨·시간대 예시, 경보 환경과 전처리·자원 계획은 과제 조건에 대한 설계 검토입니다. 위 문서·논문이 이 대회에서 해당 설계의 우위를 증명한 것은 아닙니다.